

Universidade de Fortaleza - UNIFOR

Inteligência Artificial Computacional

T296

Msc. Prof. Paulo Cirillo Souza Barbosa

Centro de Ciências Tecnológicas - CCT

Fortaleza, Ceará, Brasil





- 1 O que é Inteligência Artificial?
- 2 O que compreende um ser inteligente?
- 3 Áreas que fundamentam.
- 4 Áreas de aplicação.
- 5 Aprendizado Supervisionado (Algoritmos Lineares).
 - 5.1 Regressão.
- 6 Regressão Linear Simples/ Múltipla.
- 7 Estimação através do método dos Mínimos Quadrados Ordinário.
- 8 Equações normais dos mínimos quadrados
 - 8.1 Forma Escalar



Problemática de suas definições.

- Inteligência Artificial é o campo que estuda a síntese e análise de agentes computacionais que atuam inteligentemente (**Poole e Mackworth 2010**).
- O objetivo da Inteligência Artificial como ciência é fazer com que as máquinas façam coisas que exigiriam inteligência se fossem feitas por humanos (**Boden 1980**).
- O campo da inteligência artificial, está preocupado não apenas em compreender, mas também em construir entidades inteligentes que pode calcular como agir de forma eficaz e segura em uma ampla variedade de situações novas (**Russell e Norvig 2010**).
- Pode ser definido como o ramo da ciência da computação que se ocupa com a automação do comportamento inteligente (**Luger 2005**).



Problemática de suas definições.

- Inteligência Artificial é o campo que estuda a síntese e análise de agentes computacionais que atuam inteligentemente (**Poole e Mackworth 2010**).
- O objetivo da Inteligência Artificial como ciência é fazer com que as máquinas façam coisas que exigiriam inteligência se fossem feitas por humanos (**Boden 1980**).
- O campo da inteligência artificial, está preocupado não apenas em compreender, mas também em construir entidades inteligentes que pode calcular como agir de forma eficaz e segura em uma ampla variedade de situações novas (**Russell e Norvig 2010**).
- Pode ser definido como o ramo da ciência da computação que se ocupa com a automação do comportamento inteligente (**Luger 2005**).
- O problema de definir por completo o que é IA, está associado a tentativa de definir a própria inteligência.



Problemática com definição de inteligência.

- Um ponto de partida interessante para iniciarmos as discussões da disciplina é: **O que é um ser inteligente?**



Problemática com definição de inteligência.

- Um ponto de partida interessante para iniciarmos as discussões da disciplina é: **O que é um ser inteligente?**
- Ora, esse é um questionamento naturalmente filosófico!!
- Isto, pois, não há um consenso sobre como definir de maneira **precisa e completa** o conceito de **inteligência**.
- Existem tantas definições quanto cientistas trabalhando no tema.
- É um conceito que evolui com o progresso humano e depende tanto dos valores sociais e culturais, quanto dos paradigmas científicos atuais.



Desmistificando a Disciplina - O que é IA?

- Contudo, pode-se destacar algumas definições interessantes:
 - 1 **Dicionário:** Faculdade de compreender e raciocinar; faculdade de conhecer e aprender.
 - 2 **Dicionário:** Capacidade de aplicar conhecimento na manipulação do ambiente ou de pensar abstratamente, sendo medida por um critério objetivo.
 - 3 **Etimologia:** Inteligência vem do latim *intelligentia*, variação de *intelligere*, sendo que o prefixo inter significa “entre”, e *legere* denota “escolha”. Desta maneira, diz respeito às habilidades que um indivíduo usa para decidir sobre a melhor escolha, dentre várias possibilidades.
 - 4 **ChatGPT 3.5:** A inteligência é a capacidade de adquirir, compreender e aplicar conhecimento e habilidades para resolver problemas e tomar decisões. É uma característica complexa que inclui a capacidade de raciocinar, aprender de experiências, compreender ideias abstratas e se adaptar a novas situações.
 - 5 **Autor Desconhecido 1:** Efeito de Dunning-Kruger
 - 6 **Autor Desconhecido 2:**



Desmistificando a Disciplina - O que é IA?

- Contudo, pode-se destacar algumas definições interessantes:
 - 1 **Dicionário:** Faculdade de compreender e raciocinar; faculdade de conhecer e aprender.
 - 2 **Dicionário:** Capacidade de aplicar conhecimento na manipulação do ambiente ou de pensar abstratamente, sendo medida por um critério objetivo.
 - 3 **Etimologia:** Inteligência vem do latim *intelligentia*, variação de *intelligere*, sendo que o prefixo inter significa “entre”, e *legere* denota “escolha”. Desta maneira, diz respeito às habilidades que um indivíduo usa para decidir sobre a melhor escolha, dentre várias possibilidades.
 - 4 **ChatGPT 3.5:** A inteligência é a capacidade de adquirir, compreender e aplicar conhecimento e habilidades para resolver problemas e tomar decisões. É uma característica complexa que inclui a capacidade de raciocinar, aprender de experiências, compreender ideias abstratas e se adaptar a novas situações.
 - 5 **Autor Desconhecido 1:** Efeito de Dunning-Kruger
 - 6 **Autor Desconhecido 2:** Inteligência é como **fuleragem**. Não sei definir, mas sei reconhecer quando vejo uma.




Desmistificando a Disciplina - O que é IA?

- É possível também definir várias habilidades consideradas como características associadas à inteligência:
 - 1 Perceber o ambiente e responder com sucesso a situações não previstas.
 - 2 Adquirir e representar conhecimento sobre certos domínios.
 - 3 Capacidade de acúmulo de conhecimento em memória.
 - 4 Realizar inferências para resolução de problemas.
 - 5 Planejar um conjunto de ações em sequenciadas de modo a se atingir metas preestabelecidas.
 - 6 Realizar previsões sobre eventos futuros com base no passado.
 - 7 Ter criatividade, juízo, consciência e o dom da abstração.
 - 8 Aprender a partir da própria experiência.




Principais áreas que fundamentam e influenciam a Inteligência Artificial.






Principais áreas de aplicação da Inteligência Artificial.






Principais áreas de aplicação da Inteligência Artificial.






Principais áreas de aplicação da Inteligência Artificial.






Principais áreas de aplicação da Inteligência Artificial.






Principais áreas de aplicação da Inteligência Artificial.






Principais áreas de aplicação da Inteligência Artificial.






Principais áreas de aplicação da Inteligência Artificial.






Principais áreas de aplicação da Inteligência Artificial.





Principais áreas de aplicação da Inteligência Artificial.





Introdução.

- O que é o aprendizado de máquina?



Introdução.

- O que é o aprendizado de máquina? Pode-se definir como um conjunto de **métodos** (muitas vezes chamados de **modelos**), capazes de detectar padrões em dados, e utilizar esse padrão descoberto para prever dados futuros, ou tomar outros tipos de decisão sob incertezas.
- Existem paradigmas diferentes em que estes modelos são regidos, porém, três visões possuem mais destaques na área: **aprendizado supervisionado**; **aprendizado não supervisionado**; **aprendizado por reforço**.
- Os modelos em si poderão ter um caráter **discriminativo** ou **gerativo**.
- No paradigma supervisionado, o objetivo é aprender as relações entre entradas e saídas de determinado problema.
- No paradigma não supervisionado, o objetivo está em identificar padrões em dados que não se tem **rótulos ou observações** associadas.
- Em aprendizado por reforço, o objetivo do modelo é desempenhar ações com base em entradas, no entanto, o mesmo deverá ser avaliado a cada ação escolhida.



A problemática da aprendizagem.

- Aprendizado de Máquina (*Machine Learning*) e Reconhecimento de Padrões.
- Exemplo de utilização Aprendizado de máquina.
- Quando utilizar Aprendizado de Máquina?



A problemática da aprendizagem.

- Aprendizado de Máquina (*Machine Learning*) e Reconhecimento de Padrões.
- Exemplo de utilização Aprendizado de máquina.
- Quando utilizar Aprendizado de Máquina?
 - 1 Um padrão existe.



A problemática da aprendizagem.

- Aprendizado de Máquina (*Machine Learning*) e Reconhecimento de Padrões.
- Exemplo de utilização Aprendizado de máquina.
- Quando utilizar Aprendizado de Máquina?
 - 1 Um padrão existe.
 - 2 Não é possível descrever matematicamente.



A problemática da aprendizagem.

- Aprendizado de Máquina (*Machine Learning*) e Reconhecimento de Padrões.
- Exemplo de utilização Aprendizado de máquina.
- Quando utilizar Aprendizado de Máquina?
 - 1 Um padrão existe.
 - 2 Não é possível descrever matematicamente.
 - 3 Precisa-se de dados.



Componentes principais do aprendizado

- Considere o seguinte problema (16x16):


0	1	2	3	4
5	6	7	8	9

- Entrada: x



Componentes principais do aprendizado

- Considere o seguinte problema (16x16):




- Entrada: x (vetor com dados referentes a um dígito)
- Saída: y



Componentes principais do aprendizado

- Considere o seguinte problema (16x16):




- Entrada: x (vetor com dados referentes a um dígito)
- Saída: y (dígito referente: $0/1/2 \dots 9$)
- Deseja-se uma função $f : \mathcal{X} \longrightarrow \mathcal{Y}$. Comumente chamada de função **objetivo** (*target function*)



Componentes principais do aprendizado

- Considere o seguinte problema (16x16):




- Entrada: x (vetor com dados referentes a um dígito)
- Saída: y (dígito referente: $0/1/2 \dots 9$)
- Deseja-se uma função $f : \mathcal{X} \longrightarrow \mathcal{Y}$. Comumente chamada de função **objetivo** (*target function*)
Função esta que é **desconhecida**.



Componentes principais do aprendizado

- Considere o seguinte problema (16x16):




- Entrada: x (vetor com dados referentes a um dígito)
- Saída: y (dígito referente: $0/1/2 \dots 9$)
- Deseja-se uma função $f : \mathcal{X} \longrightarrow \mathcal{Y}$. Comumente chamada de função **objetivo** (*target function*)
Função esta que é **desconhecida**.
- O que é preciso para aprender esse padrão?



Componentes principais do aprendizado

- Considere o seguinte problema (16x16):




- Entrada: x (vetor com dados referentes a um dígito)
- Saída: y (dígito referente: $0/1/2 \dots 9$)
- Deseja-se uma função $f : \mathcal{X} \rightarrow \mathcal{Y}$. Comumente chamada de função **objetivo** (*target function*)
Função esta que é **desconhecida**.
- O que é preciso para aprender esse padrão? **Ora, Dados!!**



Componentes principais do aprendizado

- Considere o seguinte problema (16x16):




- Entrada: x (vetor com dados referentes a um dígito)
- Saída: y (dígito referente: $0/1/2 \dots 9$)
- Deseja-se uma função $f : \mathcal{X} \rightarrow \mathcal{Y}$. Comumente chamada de função **objetivo** (*target function*)
Função esta que é **desconhecida**.
- O que é preciso para aprender esse padrão? **Ora, Dados!!** $(x_1, y_1), (x_2, y_2), \dots, (x_N, y_N)$



Componentes principais do aprendizado

- Considere o seguinte problema (16x16):




- Entrada: $\mathbf{x}$ (vetor com dados referentes a um dígito)
- Saída: y (dígito referente: $0/1/2 \dots 9$)
- Deseja-se uma função $f : \mathcal{X} \rightarrow \mathcal{Y}$. Comumente chamada de função **objetivo** (*target function*)
Função esta que é **desconhecida**.
- O que é preciso para aprender esse padrão? **Ora, Dados!!** $(\mathbf{x}_1, y_1), (\mathbf{x}_2, y_2), \dots, (\mathbf{x}_N, y_N)$
- Utiliza-se os dados para estimar a função hipótese: $g : \mathcal{X} \rightarrow \mathcal{Y}$
- **Qual diferença entre f e g ?**



Componentes principais do aprendizado

- Considere o seguinte problema (16x16):



- Entrada: x (vetor com dados referentes a um dígito)
- Saída: y (dígito referente: $0/1/2 \dots 9$)
- Deseja-se uma função $f : \mathcal{X} \rightarrow \mathcal{Y}$. Comumente chamada de função **objetivo** (*target function*)
Função esta que é **desconhecida**.
- O que é preciso para aprender esse padrão? **Ora, Dados!!** $(x_1, y_1), (x_2, y_2), \dots, (x_N, y_N)$
- Utiliza-se os dados para estimar a função hipótese: $g : \mathcal{X} \rightarrow \mathcal{Y}$
- **Qual diferença entre f e g ?** g é uma aproximação de f .



Componentes principais do aprendizado

Função alvo desconhecida
 $f: X \rightarrow Y$




Exemplos de treinamento
 $(\mathbf{x}_1, y_1), \dots (\mathbf{x}_N, y_N)$



Hipótese Final
 $g \approx f$




Componentes principais do aprendizado






Componentes principais do aprendizado






Componentes principais do aprendizado





Componentes principais do aprendizado





Tipos de aprendizado

- Há diversos tipos, porém destacam-se **três** amplamente utilizados:
 - 1 Aprendizado Supervisionado (*Supervised Learning*).



Tipos de aprendizado

- Há diversos tipos, porém destacam-se **três** amplamente utilizados:
 - 1 Aprendizado Supervisionado (*Supervised Learning*).
 - 2 Aprendizado Não Supervisionado (*Unsupervised Learning*).



Tipos de aprendizado

- Há diversos tipos, porém destacam-se **três** amplamente utilizados:
 - 1 Aprendizado Supervisionado (*Supervised Learning*).
 - 2 Aprendizado Não Supervisionado (*Unsupervised Learning*).
 - 3 Aprendizado Por Reforço (*Reinforcement Learning*).




Aprendizado Supervisionado

- **(entrada, saída correta)**



Aprendizado Supervisionado

- (entrada, saída correta)






Aprendizado Não Supervisionado

- (entrada, ?)



Aprendizado Não Supervisionado

- (entrada, ?)





Aprendizado por Reforço

- (entrada, alguma saída, avaliar essa saída)
- Exemplos de aprendizado por reforço? (cotidiano).



Aprendizado por Reforço

- (**entrada**, alguma **saída**, avaliar essa saída)
- Exemplos de aprendizado por reforço? (cotidiano).
- Exemplo clássico da utilização de aprendizado por reforço






Notações, Palavras-chave utilizadas.

- Letras em minúsculo e não negritas (p) representam um número pertencente ao conjunto dos reais, ou seja, $p \in \mathbb{R}$.
- Letras minúsculas em negrito ($\mathbf{x}$), representam **vetores** que por natureza são colunas. Ou seja, aqueles vetores em que há uma quantidade específica de linhas e uma **única** coluna. Assim, $\mathbf{x} \in \mathbb{R}^{p \times 1}$.
- Letras maiúsculas e em negrito ($\mathbf{X}$) representam uma matriz de dimensão $m \times n$. Neste caso, com m linhas e n colunas. Ou seja, $\mathbf{X} \in \mathbb{R}^{m \times p}$.
- Funções poderão ser descritas com letras minúsculas ou maiúsculas seguidas de parentes e argumentos, por exemplo, $f(\cdot)$, $g(\cdot)$ ou $\mathbf{H}(\cdot)$.
- Subscritos i em x_i representa a i -ésima componente do vetor $\mathbf{x}$
- Subscritos i e j em x_{ij} representam, respectivamente, o elemento na matriz $\mathbf{X}$ alocado na i -ésima linha e j -ésima coluna.
- Subscrito i em $\mathbf{x}_i$ representa o i -ésimo vetor em uma matriz $\mathbf{X}$.



Regressão × Classificação



- Tem-se uma saída y que pode ser:
 - 1 Quantitativa
 - 2 Qualitativa (classes, categorias, fatores, variáveis discretas)



Regressão × Classificação



- Tem-se uma saída y que pode ser:
 - 1 Quantitativa
 - 2 Qualitativa (classes, categorias, fatores, variáveis discretas)
- Para ambos casos, o que é necessário para predizer a saída do sistema?



Regressão × Classificação



- Tem-se uma saída y que pode ser:
 - 1 Quantitativa
 - 2 Qualitativa (classes, categorias, fatores, variáveis discretas)
- Para ambos casos, o que é necessário para prever a saída do sistema?
 - 1 **Ex1:** Dado alguma observação atmosférica do presente e passado, deseja-se prever o **nível** de ozônio amanhã!



Regressão × Classificação



- Tem-se uma saída y que pode ser:
 - 1 Quantitativa
 - 2 Qualitativa (classes, categorias, fatores, variáveis discretas)
- Para ambos casos, o que é necessário para prever a saída do sistema?
 - 1 **Ex1:** Dado alguma observação atmosférica do presente e passado, deseja-se prever o **nível** de ozônio amanhã!
 - 2 **Ex1:** Dado valores de intensidade de pixels em escala de cinza de imagens digitalizadas de dígitos manuscritos, deseja-se prever qual **rótulo da classe**.




Regressão × Classificação



- Tem-se uma saída y que pode ser:
 - 1 Quantitativa
 - 2 Qualitativa (classes, categorias, fatores, variáveis discretas)
- Para ambos casos, o que é necessário para prever a saída do sistema?
 - 1 **Ex1:** Dado alguma observação atmosférica do presente e passado, deseja-se prever o **nível** de ozônio amanhã! (**REGRESSÃO**)
 - 2 **Ex1:** Dado valores de intensidade de *pixels* em escala de cinza de imagens digitalizadas de dígitos manuscritos, deseja-se prever qual **rótulo da classe**. (**CLASSIFICAÇÃO**)



Regressão × Classificação



- Tratando de regressões (inicialmente pelo menos):
 - 1 Necessita-se dos dados de treinamento.



Regressão × Classificação



- Tratando de regressões (inicialmente pelo menos):
 - 1 Necessita-se dos dados de treinamento.
 - 2 Observam-se as saídas para um conjunto de amostras.



Regressão × Classificação



- Tratando de regressões (inicialmente pelo menos):
 - 1 Necessita-se dos dados de treinamento.
 - 2 Observam-se as saídas para um conjunto de amostras.
 - 3 Utiliza-se estes dados para construir o modelo preditivo.



Regressão × Classificação



- Tratando de regressões (inicialmente pelo menos):
 - 1 Necessita-se dos dados de treinamento.
 - 2 Observam-se as saídas para um conjunto de amostras.
 - 3 Utiliza-se estes dados para construir o modelo preditivo.
 - 4 Este no que lhe concerne, pode realizar previsões para amostras **desconhecidas**.



Regressão × Classificação



- Tratando de regressões (inicialmente pelo menos):
 - 1 Necessita-se dos dados de treinamento.
 - 2 Observam-se as saídas para um conjunto de amostras.
 - 3 Utiliza-se estes dados para construir o modelo preditivo.
 - 4 Este no que lhe concerne, pode realizar previsões para amostras **desconhecidas**.
 - 5 **Obs:** Hipótese de correlações entre entrada saída. **Spurious Correlations**
- Este trata-se de um caso de **aprendizado supervisionado**?



Regressão × Classificação



- Tratando de regressões (inicialmente pelo menos):
 - 1 Necessita-se dos dados de treinamento.
 - 2 Observam-se as saídas para um conjunto de amostras.
 - 3 Utiliza-se estes dados para construir o modelo preditivo.
 - 4 Este no que lhe concerne, pode realizar previsões para amostras **desconhecidas**.
 - 5 **Obs:** Hipótese de correlações entre entrada saída. **Spurious Correlations**
- Este trata-se de um caso de **aprendizado supervisionado**?
 - 1 Sim! Pois, há a presença das previsões conhecidas no conjunto, para guiar o processo de treinamento do modelo.



Regressão Linear Simples/ Múltipla

- Técnica cujo objetivo principal reside justamente na investigação das relações entre variáveis e na modelagem matemática.



Regressão Linear Simples/ Múltipla

- Técnica cujo objetivo principal reside justamente na investigação das relações entre variáveis e na modelagem matemática.
 - 1 Pode ser usada na construção de um modelo que expressa o resultado de uma variável como função de uma ou mais variáveis.



Regressão Linear Simples/ Múltipla

- Técnica cujo objetivo principal reside justamente na investigação das relações entre variáveis e na modelagem matemática.
 - 1 Pode ser usada na construção de um modelo que expressa o resultado de uma variável como função de uma ou mais variáveis.
 - 2 Tal modelo pode então, ser usado para prever o resultado de uma variável em função de outra.



Regressão Linear Simples/ Múltipla

- Técnica cujo objetivo principal reside justamente na investigação das relações entre variáveis e na modelagem matemática.
 - ① Pode ser usada na construção de um modelo que expressa o resultado de uma variável como função de uma ou mais variáveis.
 - ② Tal modelo pode então, ser usado para prever o resultado de uma variável em função de outra.
- Assume-se que exista uma única variável dependente $y \in \mathbb{R}$, relacionada com p variáveis independentes, ou regressoras $x_1, x_2, \dots, x_p \in \mathbb{R}$.



Regressão Linear Simples/ Múltipla

- Técnica cujo objetivo principal reside justamente na investigação das relações entre variáveis e na modelagem matemática.
 - 1 Pode ser usada na construção de um modelo que expressa o resultado de uma variável como função de uma ou mais variáveis.
 - 2 Tal modelo pode então, ser usado para predizer o resultado de uma variável em função de outra.
- Assume-se que exista uma única variável dependente $y \in \mathbb{R}$, relacionada com p variáveis independentes, ou regressoras $x_1, x_2, \dots, x_p \in \mathbb{R}$.
 - 1 y trata-se de uma variável aleatória.
 - 2 As variáveis regressoras são medidas com erro desprezível (controladas pelo experimentador).
- O Modelo **teórico** que relaciona y e as variáveis regressoras, pode ser escrito como

$$y = f(x_1, x_2, \dots, x_p | \beta_1, \dots, \beta_p) + \varepsilon = f(\mathbf{x} | \boldsymbol{\beta}) + \varepsilon$$



Regressão Linear Simples/ Múltipla

$$y = f(x_1, x_2, \dots, x_p | \beta_1, \dots, \beta_p) + \varepsilon = f(\mathbf{x} | \boldsymbol{\beta}) + \varepsilon$$

- $f(\cdot | \cdot)$ é denominada a função de regressão.
- $\mathbf{x} \in \mathbb{R}^p$ é o vetor de variáveis regressoras.
- $\boldsymbol{\beta} \in \mathbb{R}^p$ é o vetor de parâmetros da função regressora.
- ε denota o erro aleatório (ruído) presentes na medição de y .
- O que implica esse modelo ser considerado **teórico**?



Regressão Linear Simples/ Múltipla

$$y = f(x_1, x_2, \dots, x_p | \beta_1, \dots, \beta_p) + \varepsilon = f(\mathbf{x} | \boldsymbol{\beta}) + \varepsilon$$

- $f(\cdot | \cdot)$ é denominada a função de regressão.
- $\mathbf{x} \in \mathbb{R}^p$ é o vetor de variáveis regressoras.
- $\boldsymbol{\beta} \in \mathbb{R}^p$ é o vetor de parâmetros da função regressora.
- ε denota o erro aleatório (ruído) presentes na medição de y .
- O que implica esse modelo ser considerado **teórico**?
 - 1 $f(\cdot | \cdot)$ e a componente aleatória são DESCONHECIDAS!
- A forma funcional da equação de regressão $f(\cdot)$ é realizada com base em informação **à priori**:
 - 1 Conhecimento prévio.
 - 2 Experimentação com diferentes formas funcionais.



Regressão Linear Simples/ Múltipla

- Independente da forma funcional da equação de regressão, os seus parâmetros (coeficientes) precisam ser estimados.
- O que é necessário para fazer esta estimação??



Regressão Linear Simples/ Múltipla

- Independente da forma funcional da equação de regressão, os seus parâmetros (coeficientes) precisam ser estimados.
- O que é necessário para fazer esta estimação??
- **DADOS:** um conjunto de N valores de y e suas variáveis regressoras $\{x_1, x_2, \dots, x_p\}$:

$$(x_{i1}, x_{i2}, \dots, x_{ip}, y_i), \quad i = 1, \dots, N$$

$$(\mathbf{x}_i, y_i), \quad i = 1, \dots, N$$

- A estimação de β é simbolizada por $\hat{\beta}$, que é utilizado na seguinte equação para novas predições:

$$\hat{y} = \hat{f}(x_1, x_2, \dots, x_p | \hat{\beta}) = \hat{f}(\mathbf{x} | \hat{\beta})$$



Regressão Linear Simples/ Múltipla

- A análise de regressão é dita linear quando se assume que a relação matemática entre variáveis de interesse é uma função linear dos seus parâmetros.



Regressão Linear Simples/ Múltipla

- A análise de regressão é dita linear quando se assume que a relação matemática entre variáveis de interesse é uma função linear dos seus parâmetros.
- Neste caso, o modelo passa a ser chamado de *regressão linear simples/múltipla*.
- Quando o problema de regressão linear envolve apenas uma única variável regressora x , tem-se uma *regressão linear simples*.
- Neste caso, a relação matemática entre uma única variável de entrada x e uma variável de saída y é definida por uma reta, como



Regressão Linear Simples/ Múltipla

- A análise de regressão é dita linear quando se assume que a relação matemática entre variáveis de interesse é uma função linear dos seus parâmetros.
- Neste caso, o modelo passa a ser chamado de *regressão linear simples/múltipla*.
- Quando o problema de regressão linear envolve apenas uma única variável regressora x , tem-se uma *regressão linear simples*.
- Neste caso, a relação matemática entre uma única variável de entrada x e uma variável de saída y é definida por uma reta, como

$$y = \beta_0 + \beta_1 x_1 + \varepsilon$$



Regressão Linear Simples/ Múltipla

- A análise de regressão é dita linear quando se assume que a relação matemática entre variáveis de interesse é uma função linear dos seus parâmetros.
- Neste caso, o modelo passa a ser chamado de *regressão linear simples/múltipla*.
- Quando o problema de regressão linear envolve apenas uma única variável regressora x , tem-se uma *regressão linear simples*.
- Neste caso, a relação matemática entre uma única variável de entrada x e uma variável de saída y é definida por uma reta, como

$$y = \beta_0 + \beta_1 x_1 + \varepsilon$$

- Nesta, o β_0 é o intercepto (*intercept*), e β_1 é a inclinação (*slope*) da reta.

$$\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x_1$$



Regressão Linear Simples/ Múltipla

- Para o caso de uma regressão linear múltipla, o problema pode ser escrito como

$$y = \beta_0 + \beta_1 x_1 + \cdots + \beta_p x_p + \varepsilon =$$



Regressão Linear Simples/ Múltipla

- Para o caso de uma regressão linear múltipla, o problema pode ser escrito como

$$y = \beta_0 + \beta_1 x_1 + \cdots + \beta_p x_p + \varepsilon = \boldsymbol{\beta}^T \mathbf{x} + \varepsilon$$

- Neste caso, o vetor de parâmetros $\boldsymbol{\beta} \in \mathbb{R}^{p+1}$
- Como consequência disto, a primeira componente do vetor $\mathbf{x} \in \mathbb{R}^{p+1}$ é igual a 1. Qual a interpretação geométrica disto?



Regressão Linear Simples/ Múltipla

- Para o caso de uma regressão linear múltipla, o problema pode ser escrito como

$$y = \beta_0 + \beta_1 x_1 + \cdots + \beta_p x_p + \varepsilon = \boldsymbol{\beta}^T \mathbf{x} + \varepsilon$$

- Neste caso, o vetor de parâmetros $\boldsymbol{\beta} \in \mathbb{R}^{p+1}$
- Como consequência disto, a primeira componente do vetor $\mathbf{x} \in \mathbb{R}^{p+1}$ é igual a 1. Qual a interpretação geométrica disto? Quais os valores das demais componentes?



Regressão Linear Simples/ Múltipla

- Para o caso de uma regressão linear múltipla, o problema pode ser escrito como

$$y = \beta_0 + \beta_1 x_1 + \cdots + \beta_p x_p + \varepsilon = \boldsymbol{\beta}^T \mathbf{x} + \varepsilon$$

- Neste caso, o vetor de parâmetros $\boldsymbol{\beta} \in \mathbb{R}^{p+1}$
- Como consequência disto, a primeira componente do vetor $\mathbf{x} \in \mathbb{R}^{p+1}$ é igual a 1. Qual a interpretação geométrica disto? Quais os valores das demais componentes?
- **Observações importantes:**
 - 1 Estes modelos de regressão linear simples ou múltipla, são utilizados como **funções aproximadoras** e a equação de regressão é ajustada ao conjunto de pares $(\mathbf{x}_i, y_i)$, $i = 1, \cdots N$.
 - 2 E a verdadeira equação que relaciona os conjuntos de pares?



Regressão Linear Simples/ Múltipla

- Para o caso de uma regressão linear múltipla, o problema pode ser escrito como

$$y = \beta_0 + \beta_1 x_1 + \cdots + \beta_p x_p + \varepsilon = \boldsymbol{\beta}^T \mathbf{x} + \varepsilon$$

- Neste caso, o vetor de parâmetros $\boldsymbol{\beta} \in \mathbb{R}^{p+1}$
- Como consequência disto, a primeira componente do vetor $\mathbf{x} \in \mathbb{R}^{p+1}$ é igual a 1. Qual a interpretação geométrica disto? Quais os valores das demais componentes?
- **Observações importantes:**
 - ① Estes modelos de regressão linear simples ou múltipla, são utilizados como **funções aproximadoras** e a equação de regressão é ajustada ao conjunto de pares $(\mathbf{x}_i, y_i)$, $i = 1, \dots, N$.
 - ② E a verdadeira equação que relaciona os conjuntos de pares? **É DESCONHECIDA.**



Regressão Linear Simples/ Múltipla - Implementação exemplo 1 - O QUE É O BIAS?



Regressão Linear Simples/ Múltipla - Implementação exemplo 1 - O QUE É O BIAS?

```
1 import numpy as np
2 import matplotlib.pyplot as plt
3 plt.figure(0)
4 x = np.linspace(-10,10,100)
5 for i in range(10):
6     y = np.random.randn()*x
7     plt.plot(x,y)
8 plt.grid(True)
9 plt.title("Sem intercepto")
10
11 plt.figure(1)
12 for i in range(10):
13     y = np.random.randn()*x + np.random.randn()
14     plt.plot(x,y)
15 plt.grid(True)
16 plt.title("Com intercepto")
17 plt.show()
```



Regressão Linear Simples/ Múltipla

- De maneira similar ao modelo de regressão linear simples, o modelo estimado que realiza novas predições é:

$$\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x_1 + \hat{\beta}_2 x_2 + \cdots + \hat{\beta}_n x_n = \hat{\beta}_0 + \sum_{i=0}^p \hat{\beta}_i x_i = \hat{\beta}^T \mathbf{x}$$



Regressão Linear Simples/ Múltipla

- De maneira similar ao modelo de regressão linear simples, o modelo estimado que realiza novas predições é:

$$\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x_1 + \hat{\beta}_2 x_2 + \cdots + \hat{\beta}_n x_n = \hat{\beta}_0 + \sum_{i=0}^p \hat{\beta}_i x_i = \hat{\beta}^T \mathbf{x}$$

- Qual diferença em termos de interpretação geométrica com relação ao modelo simples?
- Quais vantagens em se utilizar este modelo linear?
 - 1 Simplicidade do modelo.
 - 2 Interpretação direta ao parâmetro β_j . Permite a identificação direta de quais variáveis regressoras influenciam mais a variável de resposta.



Estimação através do método dos Mínimos Quadrados Ordinário.

- A estimação do modelo, consequentemente dos coeficientes de $\hat{\beta}$, é feita através do método dos Mínimos Quadrados Ordinário (MQO) ou do inglês, *Ordinary Least Squares* (OLS)
- **Formalização (revisão) do problema.** Para estimação do modelo (vetor de parâmetros $\hat{\beta}$), precisa-se:
 - 1 N observações (amostras) do par entrada-saída $(\mathbf{x}_i, y_i), i = 1, \dots, N$.



Estimação através do método dos Mínimos Quadrados Ordinário.

- A estimação do modelo, consequentemente dos coeficientes de $\hat{\beta}$, é feita através do método dos Mínimos Quadrados Ordinário (MQO) ou do inglês, *Ordinary Least Squares* (OLS)
- **Formalização (revisão) do problema.** Para estimação do modelo (vetor de parâmetros $\hat{\beta}$), precisa-se:
 - 1 N observações (amostras) do par entrada-saída $(\mathbf{x}_i, y_i), i = 1, \dots, N$.
 - 2 Em outras palavras, a i -ésima observação tem como resposta um escalar y_i a partir do vetor de variáveis correspondentes $\mathbf{x}_i = [x_{i1} \ x_{i2} \ \dots \ x_{ip}]^T$, em que x_{ji} representa a j -ésima variável regressora da i -ésima amostra, em que $i = \{1, \dots, N\}$ e $j = \{1, \dots, p\}$



Estimação através do método dos Mínimos Quadrados Ordinário.

- A estimação do modelo, consequentemente dos coeficientes de $\hat{\beta}$, é feita através do método dos Mínimos Quadrados Ordinário (MQO) ou do inglês, *Ordinary Least Squares* (OLS)
- **Formalização (revisão) do problema.** Para estimação do modelo (vetor de parâmetros $\hat{\beta}$), precisa-se:
 - ① N observações (amostras) do par entrada-saída $(\mathbf{x}_i, y_i), i = 1, \dots, N$.
 - ② Em outras palavras, a i -ésima observação tem como resposta um escalar y_i a partir do vetor de variáveis correspondentes $\mathbf{x}_i = [x_{i1} \ x_{i2} \ \dots \ x_{ip}]^T$, em que x_{ji} representa a j -ésima variável regressora da i -ésima amostra, em que $i = \{1, \dots, N\}$ e $j = \{1, \dots, p\}$
 - ③ Assume-se que existam (**muito**) mais observações do que incógnitas ($N \gg p$).



Estimação através do método dos Mínimos Quadrados Ordinário.

- A estimação do modelo, consequentemente dos coeficientes de $\hat{\beta}$, é feita através do método dos Mínimos Quadrados Ordinário (MQO) ou do inglês, *Ordinary Least Squares* (OLS)
- **Formalização (revisão) do problema.** Para estimação do modelo (vetor de parâmetros $\hat{\beta}$), precisa-se:
 - 1 N observações (amostras) do par entrada-saída $(\mathbf{x}_i, y_i), i = 1, \dots, N$.
 - 2 Em outras palavras, a i -ésima observação tem como resposta um escalar y_i a partir do vetor de variáveis correspondentes $\mathbf{x}_i = [x_{i1} \ x_{i2} \ \dots \ x_{ip}]^T$, em que x_{ji} representa a j -ésima variável regressora da i -ésima amostra, em que $i = \{1, \dots, N\}$ e $j = \{1, \dots, p\}$
 - 3 Assume-se que existam (**muito**) mais observações do que incógnitas ($N \gg p$).
 - 4 Assume-se que o ruído tem média 0 e variância σ^2



Estimação através do método dos Mínimos Quadrados Ordinário.

- A estimação do modelo, consequentemente dos coeficientes de $\hat{\beta}$, é feita através do método dos Mínimos Quadrados Ordinário (MQO) ou do inglês, *Ordinary Least Squares (OLS)*
- **Formalização (revisão) do problema.** Para estimação do modelo (vetor de parâmetros $\hat{\beta}$), precisa-se:
 - 1 N observações (amostras) do par entrada-saída $(\mathbf{x}_i, y_i), i = 1, \dots, N$.
 - 2 Em outras palavras, a i -ésima observação tem como resposta um escalar y_i a partir do vetor de variáveis correspondentes $\mathbf{x}_i = [x_{i1} \ x_{i2} \ \dots \ x_{ip}]^T$, em que x_{ji} representa a j -ésima variável regressora da i -ésima amostra, em que $i = \{1, \dots, N\}$ e $j = \{1, \dots, p\}$
 - 3 Assume-se que existam (**muito**) mais observações do que incógnitas ($N \gg p$).
 - 4 Assume-se que o ruído tem média 0 e variância σ^2
 - 5 Assume-se que as observações em ε são não-correlacionadas.



Estimação através do método dos Mínimos Quadrados Ordinário.

- A estimação do modelo, consequentemente dos coeficientes de $\hat{\beta}$, é feita através do método dos Mínimos Quadrados Ordinário (MQO) ou do inglês, *Ordinary Least Squares* (OLS)
- **Formalização (revisão) do problema.** Para estimação do modelo (vetor de parâmetros $\hat{\beta}$), precisa-se:
 - 1 N observações (amostras) do par entrada-saída $(\mathbf{x}_i, y_i), i = 1, \dots, N$.
 - 2 Em outras palavras, a i -ésima observação tem como resposta um escalar y_i a partir do vetor de variáveis correspondentes $\mathbf{x}_i = [x_{i1} \ x_{i2} \ \dots \ x_{ip}]^T$, em que x_{ji} representa a j -ésima variável regressora da i -ésima amostra, em que $i = \{1, \dots, N\}$ e $j = \{1, \dots, p\}$
 - 3 Assume-se que existam (**muito**) mais observações do que incógnitas ($N \gg p$).
 - 4 Assume-se que o ruído tem média 0 e variância σ^2
 - 5 Assume-se que as observações em ε são não-correlacionadas.
- **Obs:** A estimação mostrada, é consolidadas para o caso geral (múltiplas variáveis regressoras)



Estimação através do método dos Mínimos Quadrados Ordinário.

- O problema pode ser expandido, para abranger todas as observações:

$$\beta_0 + \beta_1 x_{11} + \beta_2 x_{12} + \cdots + \beta_p x_{1p} + \varepsilon_1 = y_1$$

$$\beta_0 + \beta_1 x_{21} + \beta_2 x_{22} + \cdots + \beta_p x_{2p} + \varepsilon_2 = y_2$$

$$\vdots$$

$$\beta_0 + \beta_1 x_{N1} + \beta_2 x_{N2} + \cdots + \beta_p x_{Np} + \varepsilon_N = y_N$$

- Em notação matricial, o sistema pode ser descrito como:



Estimação através do método dos Mínimos Quadrados Ordinário.

- O problema pode ser expandido, para abranger todas as observações:

$$\beta_0 + \beta_1 x_{11} + \beta_2 x_{12} + \cdots + \beta_p x_{1p} + \varepsilon_1 = y_1$$

$$\beta_0 + \beta_1 x_{21} + \beta_2 x_{22} + \cdots + \beta_p x_{2p} + \varepsilon_2 = y_2$$

$$\vdots$$

$$\beta_0 + \beta_1 x_{N1} + \beta_2 x_{N2} + \cdots + \beta_p x_{Np} + \varepsilon_N = y_N$$

- Em notação matricial, o sistema pode ser descrito como:

$$\mathbf{y} = \mathbf{X}\boldsymbol{\beta} + \boldsymbol{\varepsilon}$$

- Nesta, é possível verificar que a variável de resposta é uma função linear das variáveis regressoras.



Estimação através do método dos Mínimos Quadrados Ordinário.

$$\mathbf{y} = \mathbf{X}\boldsymbol{\beta} + \boldsymbol{\varepsilon}$$

- Em que $\mathbf{y}$ e $\boldsymbol{\varepsilon} \in \mathbb{R}^N$, $\mathbf{X} \in \mathbb{R}^{N \times (p+1)}$ e $\boldsymbol{\beta} \in \mathbb{R}^{p+1}$

$$\mathbf{y} = \begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_N \end{bmatrix}_{N \times 1}, \quad \mathbf{X} = \begin{bmatrix} 1 & x_{11} & x_{12} & \cdots & x_{1p} \\ 1 & x_{21} & x_{22} & \cdots & x_{2p} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 1 & x_{N1} & x_{N2} & \cdots & x_{Np} \end{bmatrix}_{N \times (p+1)}, \quad \boldsymbol{\beta} = \begin{bmatrix} \beta_0 \\ \beta_1 \\ \vdots \\ \beta_p \end{bmatrix}_{(p+1) \times 1}, \quad \boldsymbol{\varepsilon} = \begin{bmatrix} \varepsilon_1 \\ \varepsilon_2 \\ \vdots \\ \varepsilon_N \end{bmatrix}_{N \times 1}$$



Estimação através do método dos Mínimos Quadrados Ordinário.

- A técnica de estimação dos coeficientes de regressão β corresponde a minimização dos **desvios** ε_i entre os valores observados de y_i e o hiperplano de regressão. Ou seja, fazer com que a soma dos quadrados dos desvios seja mínima.
- Para uma observação este desvio é:

$$y = \beta_0 + \sum_{j=1}^p \beta_j x_j + \varepsilon$$



Estimação através do método dos Mínimos Quadrados Ordinário.

- A técnica de estimação dos coeficientes de regressão β corresponde a minimização dos **desvios** ε_i entre os valores observados de y_i e o hiperplano de regressão. Ou seja, fazer com que a soma dos quadrados dos desvios seja mínima.
- Para uma observação este desvio é:

$$y = \beta_0 + \sum_{j=1}^p \beta_j x_j + \varepsilon \qquad \left(y - \left[\beta_0 + \sum_{j=1}^p \beta_j x_j \right] \right)^2 = \varepsilon^2$$

- Normalmente esta equação é conhecida como **função custo**. Então, para todas as observações de treinamento, a estimação dos coeficientes pelo método dos MQO é realizar a minimização da função custo $J(\cdot)$:

$$J(\beta_0, \beta_1, \dots, \beta_p) = \sum_{i=1}^N \varepsilon^2$$



Estimação através do método dos Mínimos Quadrados Ordinário.

$$\begin{aligned} J(\beta_0, \beta_1, \dots, \beta_p) &= \sum_{i=1}^n \varepsilon^2 \\ &= \sum_{i=1}^n \left(y_i - \beta_0 - \sum_{j=1}^p \beta_j x_j \right)^2 \end{aligned}$$

- Ou em sua forma vetorial:

$$\begin{aligned} \mathbf{y} &= \mathbf{X}\boldsymbol{\beta} + \boldsymbol{\varepsilon} & \boldsymbol{\varepsilon} &= \mathbf{y} - \mathbf{X}\boldsymbol{\beta} \\ J(\boldsymbol{\beta}) &= \|\boldsymbol{\varepsilon}\|_2^2 \end{aligned}$$



Estimação através do método dos Mínimos Quadrados Ordinário.

$$\begin{aligned} J(\beta_0, \beta_1, \dots, \beta_p) &= \sum_{i=1}^n \varepsilon^2 \\ &= \sum_{i=1}^n \left(y_i - \beta_0 - \sum_{j=1}^p \beta_j x_j \right)^2 \end{aligned}$$

- Ou em sua forma vetorial:

$$\begin{aligned} \mathbf{y} &= \mathbf{X}\boldsymbol{\beta} + \boldsymbol{\varepsilon} & \boldsymbol{\varepsilon} &= \mathbf{y} - \mathbf{X}\boldsymbol{\beta} \\ J(\boldsymbol{\beta}) &= \|\boldsymbol{\varepsilon}\|_2^2 = \boldsymbol{\varepsilon}^T \boldsymbol{\varepsilon} \end{aligned}$$



Estimação através do método dos Mínimos Quadrados Ordinário.

$$\begin{aligned} J(\beta_0, \beta_1, \dots, \beta_p) &= \sum_{i=1}^n \varepsilon^2 \\ &= \sum_{i=1}^n \left(y_i - \beta_0 - \sum_{j=1}^p \beta_j x_j \right)^2 \end{aligned}$$

- Ou em sua forma vetorial:

$$\begin{aligned} \mathbf{y} &= \mathbf{X}\boldsymbol{\beta} + \boldsymbol{\varepsilon} & \boldsymbol{\varepsilon} &= \mathbf{y} - \mathbf{X}\boldsymbol{\beta} \\ J(\boldsymbol{\beta}) &= \|\boldsymbol{\varepsilon}\|_2^2 = \boldsymbol{\varepsilon}^T \boldsymbol{\varepsilon} = (\mathbf{y} - \mathbf{X}\boldsymbol{\beta})^T (\mathbf{y} - \mathbf{X}\boldsymbol{\beta}) \end{aligned}$$

Obs: Qual a interpretação da minimização desta equação em forma vetorial?



Equações normais dos mínimos quadrados (Forma Escalar)

- A função $J(\beta_0, \beta_1, \dots, \beta_p)$ deve ser minimizada individualmente em relação a cada um dos parâmetros.
- Portanto a derivada parcial de $J(\beta_0, \beta_1, \dots, \beta_p)$ deve ser tomada em relação a cada parâmetro $\beta_j, j = 1, \dots, p$ e igualada a zero.

$$\frac{\partial J}{\partial \beta_0} = -2 \sum_{i=1}^N \left(y_i - \hat{\beta}_0 - \sum_{j=1}^p \hat{\beta}_j x_{ij} \right) = 0$$

$$\frac{\partial J}{\partial \beta_j} = -2 \sum_{i=1}^N x_{ij} \left(y_i - \hat{\beta}_0 - \sum_{j=1}^p \hat{\beta}_j x_{ij} \right) = 0, j = 1, 2, \dots, p$$



Equações normais dos mínimos quadrados (Forma Escalar)

- Com a resolução das equações anteriores, pode-se montar um sistema conhecido como **equações normais de mínimos quadrados**, em sua forma escalar:

$$\begin{aligned} n\hat{\beta}_0 + \hat{\beta}_1 \sum_{i=1}^N x_{i1} + \hat{\beta}_2 \sum_{i=1}^N x_{i2} + \cdots + \hat{\beta}_p \sum_{i=1}^N x_{ip} &= \sum_{i=1}^N y_i, \\ N\hat{\beta}_0 \sum_{i=1}^N x_{i1} + \hat{\beta}_1 \sum_{i=1}^N x_{i1}^2 + \hat{\beta}_2 \sum_{i=1}^N x_{i1}x_{i2} + \cdots + \hat{\beta}_p \sum_{i=1}^N x_{i1}x_{ip} &= \sum_{i=1}^N x_{i1}y_i, \\ \vdots & \\ N\hat{\beta}_0 \sum_{i=1}^N x_{ip} + \hat{\beta}_1 \sum_{i=1}^N x_{ip} + \hat{\beta}_2 \sum_{i=1}^N x_{ip}x_{i2} + \cdots + \hat{\beta}_p \sum_{i=1}^N x_{ip}^2 &= \sum_{i=1}^N x_{ip}y_i, \end{aligned}$$



Estimação através do método dos Mínimos Quadrados Ordinário.



- *méthode des moindres carrés* - **Legendre** (1805).



- Formalização estatística e suposição de erro normal (1809).



Estimação através do método dos Mínimos Quadrados Ordinário.

$$J(\beta) = \|\epsilon\|_2^2 = \epsilon^T \epsilon = (\mathbf{y} - \mathbf{X}\beta)^T (\mathbf{y} - \mathbf{X}\beta)$$



Estimação através do método dos Mínimos Quadrados Ordinário.

$$\begin{aligned} J(\beta) &= \|\epsilon\|_2^2 = \epsilon^T \epsilon = (\mathbf{y} - \mathbf{X}\beta)^T (\mathbf{y} - \mathbf{X}\beta) \\ &= \mathbf{y}^T \mathbf{y} - 2\beta^T \mathbf{X}^T \mathbf{y} + \beta^T \mathbf{X}^T \mathbf{X} \beta \end{aligned}$$



Estimação através do método dos Mínimos Quadrados Ordinário.

$$J(\beta) = \|\epsilon\|_2^2 = \epsilon^T \epsilon = (\mathbf{y} - \mathbf{X}\beta)^T (\mathbf{y} - \mathbf{X}\beta)$$

$$= \mathbf{y}^T \mathbf{y} - 2\beta^T \mathbf{X}^T \mathbf{y} + \beta^T \mathbf{X}^T \mathbf{X} \beta$$

$$\frac{\partial J}{\partial \beta} = \mathbf{0} - 2\mathbf{X}^T \mathbf{y} + 2\mathbf{X}^T \mathbf{X} \beta = 0$$



Estimação através do método dos Mínimos Quadrados Ordinário.

$$J(\beta) = \|\epsilon\|_2^2 = \epsilon^T \epsilon = (\mathbf{y} - \mathbf{X}\beta)^T (\mathbf{y} - \mathbf{X}\beta)$$

$$= \mathbf{y}^T \mathbf{y} - 2\beta^T \mathbf{X}^T \mathbf{y} + \beta^T \mathbf{X}^T \mathbf{X} \beta$$

$$\frac{\partial J}{\partial \beta} = \mathbf{0} - 2\mathbf{X}^T \mathbf{y} + 2\mathbf{X}^T \mathbf{X} \beta = 0$$

$$\mathbf{X}^T \mathbf{X} \beta = \mathbf{X}^T \mathbf{y}$$



Estimação através do método dos Mínimos Quadrados Ordinário.

$$J(\beta) = \|\epsilon\|_2^2 = \epsilon^T \epsilon = (\mathbf{y} - \mathbf{X}\beta)^T (\mathbf{y} - \mathbf{X}\beta)$$

$$= \mathbf{y}^T \mathbf{y} - 2\beta^T \mathbf{X}^T \mathbf{y} + \beta^T \mathbf{X}^T \mathbf{X} \beta$$

$$\frac{\partial J}{\partial \beta} = \mathbf{0} - 2\mathbf{X}^T \mathbf{y} + 2\mathbf{X}^T \mathbf{X} \beta = 0$$

$$\mathbf{X}^T \mathbf{X} \beta = \mathbf{X}^T \mathbf{y}$$

$$\hat{\beta} = (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{y}$$



Estimação através do método dos Mínimos Quadrados Ordinário.

$$J(\beta) = \|\epsilon\|_2^2 = \epsilon^T \epsilon = (\mathbf{y} - \mathbf{X}\beta)^T (\mathbf{y} - \mathbf{X}\beta)$$

$$= \mathbf{y}^T \mathbf{y} - 2\beta^T \mathbf{X}^T \mathbf{y} + \beta^T \mathbf{X}^T \mathbf{X} \beta$$

$$\frac{\partial J}{\partial \beta} = \mathbf{0} - 2\mathbf{X}^T \mathbf{y} + 2\mathbf{X}^T \mathbf{X} \beta = 0$$

$$\mathbf{X}^T \mathbf{X} \beta = \mathbf{X}^T \mathbf{y}$$

$$\hat{\beta} = (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{y}$$

$$\hat{\beta} = \mathbf{X}^\dagger \mathbf{y}$$



Estimação através do método dos Mínimos Quadrados Ordinário.

- O modelo preditivo pode realizar novas previsões com: $\hat{y} = \mathbf{x}\hat{\beta}$



Estimação através do método dos Mínimos Quadrados Ordinário.

- O modelo preditivo pode realizar novas previsões com: $\hat{y} = \mathbf{X}\hat{\beta}$

Exemplo prático para regressão linear simples.

Índice	País	Cigarro per capita	Mortes por milhão de pessoas
1	Austrália	480	180
2	Canadá	500	150
3	Dinamarca	380	170
4	Finlândia	1100	350
5	Grã Bretanha	1100	460
6	Islândia	230	60
7	Holanda	490	240
8	Noruega	250	90
9	Suécia	300	110
10	Suíça	510	250

Tabela 1: Consumo per capita de cigarros em vários países em 1930 e as taxas de morte por câncer de pulmão em 1950 (Freedman et al., 2007).



Exemplo prático para regressão linear simples.

Índice	País	Cigarro per capita	Mortes por milhão de pessoas
1	Austrália	480	180
2	Canadá	500	150
3	Dinamarca	380	170
4	Finlândia	1100	350
5	Grã Bretanha	1100	460
6	Islândia	230	60
7	Holanda	490	240
8	Noruega	250	90
9	Suécia	300	110
10	Suíça	510	250

Tabela 2: Consumo per capita de cigarros em vários países em 1930 e as taxas de morte por câncer de pulmão em 1950 (Freedman et al., 2007).



Exemplo prático para regressão linear simples.

- Para o presente conjunto de dados, informe os valores de p e N . Além disso, existem quantos parâmetros da função regressora?



Exemplo prático para regressão linear simples.

- Para o presente conjunto de dados, informe os valores de p e N . Além disso, existem quantos parâmetros da função regressora?
- Pode-se plotar um gráfico de dispersão dada a relação entre x_i e y_i , $i = 1, \dots, 10$? Se sim, faça.



Exemplo prático para regressão linear simples.

- Para o presente conjunto de dados, informe os valores de p e N . Além disso, existem quantos parâmetros da função regressora?
- Pode-se plotar um gráfico de dispersão dada a relação entre x_i e y_i , $i = 1, \dots, 10$? Se sim, faça.
- Através do método dos mínimos quadrados ordinário, faça a estimação dos parâmetros da função regressora.
- Trace a reta que melhor ajusta estes dados.
- Dado uma nova amostra $x_{11} = 400$, qual valor de y_{11} ? Plote o ponto no gráfico de dispersão.
- **Se você estiver de posse de dados que possuam dois preditores e saídas quantitativas, é possível gerar um gráfico do modelo?**



Regressão Linear Simples - Implementação exemplo 2

```
1 import numpy as np
2 import matplotlib.pyplot as plt
3 #Algoritmo desenvolvido por: Paulo Cirillo Souza Barbosa.
4 #Exemplo de ajuste de reta utilizando modelo estimado pelo
5 # método dos mínimos quadrados ordinário.
6 x = np.array([480 ,500 ,380 ,1100,1100,230 ,490 ,250 ,300 ,510 ])
7 x.shape = (len(x),1)
8 y = np.array([180,150,170,350,460,60,240,90,110,250])
9 y.shape = (len(y),1)
10 plt.scatter(x,y,color='orange')
11 X = np.concatenate((np.ones((len(x),1)),x),axis=1)
12
13 #Estimação do modelo:
14 B = np.linalg.pinv(X.T@X)@X.T@y
15
16 x_axis = np.linspace(0,1200,1200)
17 x_axis.shape = (len(x_axis),1)
18 ones = np.ones((len(x_axis),1))
19 X_new = np.concatenate((ones,x_axis),axis=1)
20 Y_pred = X_new@B
21 plt.plot(x_axis,Y_pred,color='blue')
22 plt.show()
```




Formalizações de problemas reais.

- Quando se deseja resolver um problema associado a tarefa de regressão/classificação, aplicam-se os passos descritos nos slides anteriores.
- É de interesse prático tentar identificar um modelo que consegue resolver o problema, essa definição é de total controle do projetista do sistema. Contudo, muitas vezes ao realizar uma análise visual dos dados, é possível levantar hipóteses de qual(is) modelo(s) conseguem resolver o problema.
- Dessa maneira, é importante medir como tais modelos desempenham para decidir qual é o ideal para solução do problema.
- Uma maneira de identificar qual modelo tem o melhor desempenho num grupo de modelos, é utilizar técnicas de validação.
 - 1 Validação *Leave-One-Out*.
 - 2 Validação cruzada com k -dobras.
 - 3 Validação por simulações de Monte Carlo.
 - 4 Validação de Amostragem Aleatória.



Validação com k -dobras





Validação de Amostragem Aleatória





Pseudocódigo para validação de modelos.

Algorithm 1: Pseudocódigo Treinamento, Teste e Validação.

- 1: Colete dados.
 - 2: Organize os dados em Variáveis Regressoras (X) e Variável Objetivo(Y).
 - 3: Faça uma análise por inspeção visual dos dados.
 - 4: Aplique o pré-processamento se necessário.
 - 5: Defina a quantidade R de rodadas.
 - 6: Crie uma lista vazia para cada modelo a ser testado representando uma medida de erro/acerto.
 - 7: **for** r começando de 0 até R **do**
 - 8: Embaralhe amostras de X e Y em novas variáveis $X_{\text{embaralhado}}$ e $Y_{\text{embaralhado}}$.
 - 9: Segmente as amostras de X e Y **embaralhados** em $(X_{\text{treinamento}}, Y_{\text{treinamento}})$ e $(X_{\text{teste}}, Y_{\text{teste}})$ utilizando uma proporção definida (90/10, 80/20, 70/30).
 - 10: Treine os modelos escolhidos utilizando apenas os dados de treinamento.
 - 11: Aplique cada dado de teste nos modelos treinados.
 - 12: Produza uma medida de erro/acerto baseado na resposta do modelo (Y_{predito}) e Y_{teste} (para regressão, essa medida pode ser a **média de desvios quadráticos**).
 - 13: Armazene essa medida na lista criada e considerando cada modelo.
 - 14: **end for**
 - 15: Compute a média, desvio padrão, maior valor e menor valor das R medidas de erro/acerto existentes em cada lista preenchida. É interessante também plotar um gráfico dessas informações.
-



Métricas de desempenho de modelos.

- Independente do tipo de validação cruzada escolhida, para cada rodada do algoritmo, é necessário ser medido o desempenho do modelo.
- Isso é feito através de algumas métricas de desempenho, as quais serão discutidas no presente momento.
- Como definição preliminar, considera-se que para a tarefa de regressão, seja utilizado um conjunto de dados com $\mathbf{X}_{treino} \in \mathbb{R}^{N_{treino} \times p}$ e um vetor de variáveis dependentes $\mathbf{y} \in \mathbb{R}^{N_{treino}}$. Após o processo de treinamento, é de desejo saber como é o seu desempenho para dados desconhecidos, ou seja, uma massa de dados $\mathbf{X}_{teste} \in \mathbb{R}^{N_{teste} \times p}$ e um vetor de variáveis dependentes $\mathbf{y} \in \mathbb{R}^{N_{teste}}$
- Ao inserir os dados de teste na forma funcional da equação de predição ($\mathbf{X}\hat{\beta}$), o modelo produzirá um vetor de predições $\hat{\mathbf{y}} \in \mathbb{R}^{N_{teste}}$.
- Assim, com base no real que é representado no vetor $\mathbf{y} \in \mathbb{R}^{N_{teste}}$, e no vetor de predição do modelo $\hat{\mathbf{y}} \in \mathbb{R}^{N_{teste}}$, pode-se computar uma métrica de desempenho.



Métricas de desempenho de modelos.

- A primeira métrica já foi vista, pois aparece na dedução dos mínimos quadrados ordinários. Essa mede o somatório dos desvios quadráticos, e no contexto de avaliação de desempenho ela comumente é chamada de Soma de Erros Quadráticos (SSE - *Sum of the Squared Errors*)

$$SSE = \sum_{i=1}^{N_{teste}} (y_i - \hat{y}_i)^2$$

- A depender da situação dos dados, essa métrica pode produzir valores muito altos, neste caso, adota-se a utilização da Média de Erros Quadráticos (MSE - *Mean Squared Errors*)

$$MSE = \frac{1}{N} \sum_{n=1}^{N_{te}} (y_n - \hat{y}_n)^2$$



Métricas de desempenho de modelos.

- Uma terceira métrica complementar e que dá outras percepções além do que as outras fazem, chama-se Coeficiente de Determinação (R^2) e mede a quantidade de variância nos dados que é explicada pelo modelo de regressão

$$R^2 = 1 - \frac{\sum_{i=1}^{N_{teste}} (y_i - \hat{y}_i)^2}{\sum_{i=1}^{N_{teste}} (y_i - \bar{y}_i)^2} = 1 - \frac{SSE}{SST}$$

- Na equação SST é a soma total de quadrados, e representa o somatório de desvios quadráticos entre o predito pelo modelo ($\hat{y}_i$) e a média dos valores reais ($\bar{y}_i$).
- Em termos de interpretação, duas situações distintas podem ocorrer:
 - 1 $0 \leq R^2 \leq 1$
 - 2 $R^2 < 0$



Métricas de desempenho de modelos.

- Em termos de interpretação, duas situações distintas podem ocorrer:
 - 1 $0 \leq R^2 \leq 1$ Neste caso, a métrica representa a variância dos dados que é explicada pelo modelo. Quanto mais próximo de um, melhor o modelo entende os dados apresentados. Quanto mais próximo de zero, porém ainda positivo, o modelo perde a capacidade de capturar as relações fornecidas, no entanto ele ainda será melhor que a média da variável dependente. Quando igual a zero, o modelo captura tão bem quanto a média da variável dependente.
 - 2 $R^2 < 0$. Caso esse seja o resultado, significa que o modelo é pior que a média em termos da variância explicada pelo modelo.



Formalização de problemas em geral.

- Após essa descrição sólida que se utiliza de conceitos da álgebra linear, cálculo diferencial e estatística, faz sentido sair um pouco da abstração para entender as motivações para se utilizar modelos (no sentido genérico) de IA.
- O ato de desenvolver um modelo **generalista** é vantajoso no sentido de que um mesmo modelo consegue aprender relações de diferentes problemas e consegue também se adaptar a mudanças daquele problema.
- Os slides seguintes, possuem um teor prático e que está de "mãos-dadas" com os fundamentos exibidos nos slides anteriores.
- Assim, a pretensão é que você consiga realizar conexões sobre **como, quando e porquê** utilizar tais modelos generalistas.



Exemplo Contextualizado.

- Considere o seguinte exemplo hipotético:
 - 1 Você é um projetista de modelos de IA, e seu cliente te pediu para desenvolver um sistema que lhe auxilia em suas pesquisas. Esse cliente é um químico que faz diversos experimentos de solubilidade a partir de relações estruturais de componentes químicos.
 - 2 Em um momento inicial, o cliente resolveu apenas lhe fornecer parte dos experimentos e lhe enviou dados referentes a 951 amostras com os preditores (variáveis regressoras) **quantidade de carbono**(x_1) e **peso molecular**(x_2). Em conjunto dessas informações, ele também lhe enviou as 951 medições da de solubilidade (variável dependente) realizadas.
 - 3 Com essas informações, é possível desenvolver um sistema inteligente que **aprende** as relações entre ($x_{\text{numeroCarbono}}$, $x_{\text{pesoMolecular}}$, $y_{\text{solubilidade}}$)?
 - 4 Para o presente problema, quais os valores de N e p ?
 - 5 Após o modelo ser estimado, faça a predição da solubilidade associada a amostra ($x_1 = 11$, $x_2 = 190, 27$).
 - 6 Como o modelo seria se não fosse adicionado a coluna de 1s? Como o modelo seria caso, sua estimativa tivesse apenas o intercepto (sendo este valor, apenas a média da variável dependente)?



Passos comuns ao desenvolver algoritmos que aprendem a partir de dados.

- Foi comentado no passado que os passos comuns para desenvolver um modelo de IA generalista, tem a seguinte sequência:
 - 1 Coleta de dados.
 - Fornecidos por demanda.
 - Participação do processo de aquisição dos dados.
 - Dados sintetizados (**Orange**).



Passos comuns ao desenvolver algoritmos que aprendem a partir de dados.

- Foi comentado no passado que os passos comuns para desenvolver um modelo de IA generalista, tem a seguinte sequência:
 - 1 Coleta de dados.
 - Fornecidos por demanda.
 - Participação do processo de aquisição dos dados.
 - Dados sintetizados (**Orange**).
 - 2 Análise Exploratória dos dados.
 - Fazer afirmações e/ou tirar conclusões (**inferência**) a partir da população de dados.
 - Identificar padrões, correlações, e tendências.
 - Identificar as possíveis anomalias e *outliers*.
 - Para isso, faz-se o uso de de gráficos como, por exemplo, espalhamento(*scatter*), *box-plot*, *violin-plot*, **histograma**, **matriz de coeficientes de correlação**
 - Caso haja uma alta dimensionalidade dos dados, pode-se utilizar abordagens como gráficos tridimensionais paralelos, ou métodos como *t-SNE*.



Formalizações de problemas reais.

- Foi comentado no passado que os passos comuns para desenvolver um modelo de IA generalista, tem a seguinte sequência:
 - 3 Pré-processamento.
 - Remoção/Preenchimento de amostras com informações faltantes.
 - Remoção de possíveis anomalias e *outliers*.
 - Escalonamento/Padronização dos dados.
 - Balanceamento de classes.
 - Codificação de características (*feature encoding*).



Formalizações de problemas reais.

- Foi comentado no passado que os passos comuns para desenvolver um modelo de IA generalista, tem a seguinte sequência:
 - 3 Pré-processamento.
 - Remoção/Preenchimento de amostras com informações faltantes.
 - Remoção de possíveis anomalias e *outliers*.
 - Escalonamento/Padronização dos dados.
 - Balanceamento de classes.
 - Codificação de características (*feature encoding*).
 - 4 Processamento.
 - Filtros, por exemplo, Passa-faixas, Médias, Gaussiano, Kalman, ou outros.
 - Redução de dimensionalidade, por exemplo, PCA, LDA, ...



Formalizações de problemas reais.

- Foi comentado no passado que os passos comuns para desenvolver um modelo de IA generalista, tem a seguinte sequência:
 - 4 Extração e Seleção de Características.
 - Projeto de novas *features* que conseguem capturar as informações relevantes nos dados.
 - Para atingir isso, podem ser aplicados métodos de aprendizado de máquina também, mas com a tarefa de extrair e selecionar as melhores características que serão enviadas ao modelo classificador/regressor.
 - É de interesse que nessa etapa utilize-se métodos baseados no aprendizado não supervisionado e com uma quantidade pequena ou nula de hiperparâmetros.
 - Exemplos de tais métodos são: matriz de covariância, PSD, Funções de Kernel, camada Convolutacional de uma CNN.



Formalizações de problemas reais.

- Foi comentado no passado que os passos comuns para desenvolver um modelo de IA generalista, tem a seguinte sequência:
 - 5 Modelo de classificação/regressão
 - Etapa em que o modelo treina a partir de exemplos, ou seja, seu aprendizado é condicionado as características das informações fornecidas ao modelo.
 - Nessa Etapa da disciplina, serão expostos os métodos estatísticos como OLS e OLS regularizado, bem como os modelos estatísticos e probabilísticos que utilizam-se da regra de Bayes.
 - Na AV3, serão estudados os modelos conexionistas, por exemplo, Perceptron Simples, ADALINE, Perceptron de Múltiplas Camadas e Rede Função de Base Radial.




Regressão linear.

- É possível utilizar o método dos mínimos quadrados para estimar um "sistema" que resolve um problema de **classificação**?

Definição do problema


- Considere que exista um sistema que consegue prever expressões faciais forçadas, dado sinais de eletromiografia.
- Imagine que esse sistema faça a aquisição dos sinais através de dois sensores posicionados no corrugador do supercílio e no zigomático maior.





Definição do problema

- Considere que o dispositivo que faz as aquisições do sinal com uma taxa de amostragem de 1KHz.
- Em uma determinada análise, um pesquisador se submeteu ao processo de aquisição dos sinais para cinco diferentes gestos.
- Considere que para cada gesto a coleta dos dados foi realizada durante 1 segundo.





Conjunto de dados.

- Cada valor de biopotencial medido, pode ser entendido como uma variável que o sistema usa para decidir qual gesto é posto.
- Pode-se organizar as informações em uma matriz, referente as



Conjunto de dados.

- Cada valor de biopotencial medido, pode ser entendido como uma variável que o sistema usa para decidir qual gesto é posto.
- Pode-se organizar as informações em uma matriz, referente as 5000 amostras com as variáveis de biopotencial medidas.
- De posse do presente conjunto de dados, usando a Álgebra Linear é possível construir esse sistema que consegue classificar os cinco diferentes gestos?



Conjunto de dados.

- Cada valor de biopotencial medido, pode ser entendido como uma variável que o sistema usa para decidir qual gesto é posto.
- Pode-se organizar as informações em uma matriz, referente as 5000 amostras com as variáveis de biopotencial medidas.
- De posse do presente conjunto de dados, usando a Álgebra Linear é possível construir esse sistema que consegue classificar os cinco diferentes gestos?
- É necessário formular o problema de classificação com uma **transformação linear** $y = xW$



Conjunto de dados.

- Para **uma** amostra, o vetor de características pode ser representado por:

$$\mathbf{x} = \begin{bmatrix} x_1 & x_2 \end{bmatrix} =$$



Conjunto de dados.

- Para **uma** amostra, o vetor de características pode ser representado por:

$$\mathbf{x} = [x_1 \ x_2] = [\text{Dado lido pelo sensor 1} \ \text{Dado lido pelo sensor 2}]$$

- Para o presente problema $x_j \in \{0, 1, 2, \dots, 4095\}, j = 1, 2$



Conjunto de dados.

- Para **uma** amostra, o vetor de características pode ser representado por:

$$\mathbf{x} = [x_1 \ x_2] = [\text{Dado lido pelo sensor 1} \ \text{Dado lido pelo sensor 2}]$$

- Para o presente problema $x_j \in \{0, 1, 2, \dots, 4095\}$, $j = 1, 2$ que é referente a uma leitura correspondente a 12 bits do conversor A/D.



Conjunto de dados.

- Considerando que cada amostra do conjunto de dados, é rotulada com um **texto** referente ao gesto daquela amostra. No presente conjunto existem amostras referentes aos gestos: **Neutro**, **Sorrindo**, **Aberto**, **Surpreso** e **Rabugento**.



Conjunto de dados.

- Considerando que cada amostra do conjunto de dados, é rotulada com um **texto** referente ao gesto daquela amostra. No presente conjunto existem amostras referentes aos gestos: **Neutro**, **Sorrindo**, **Aberto**, **Surpreso** e **Rabugento**.
- Para **uma** amostra, também associa-se o vetor-código (o rótulo), que possui dimensão ($c = 5$), ou seja, um identificador para o gesto posto.

$$\text{Neutro: } \mathbf{y} = [1 \quad -1 \quad -1 \quad -1 \quad -1]$$

$$\text{Sorrindo: } \mathbf{y} = [-1 \quad 1 \quad -1 \quad -1 \quad -1] \quad \text{Aberto: } \mathbf{y} = [-1 \quad -1 \quad 1 \quad -1 \quad -1]$$

$$\text{Surpreso: } \mathbf{y} = [-1 \quad -1 \quad -1 \quad 1 \quad -1] \quad \text{Rabugento: } \mathbf{y} = [-1 \quad -1 \quad -1 \quad -1 \quad 1]$$



Conjunto de dados.

- Note que o conjunto de dados tem $N = 5000$ vetores $\mathbf{x}_i \in \mathbb{R}^{1 \times 2}$ e 5000 vetores $\mathbf{y}_i \in \mathbb{R}^{1 \times 5}, i = 1, \dots, 5000$.
- O índice i denota a i -ésima amostra presente no conjunto de dados.
- É de interesse determinar uma matriz $\mathbf{W}$ que para um determinado dado vetor de entrada (amostra) $\mathbf{x}_i$ forneça uma predição do vetor-código associado ao gesto correspondente:

$$\mathbf{y}_i = \mathbf{x}_i \mathbf{W}, \quad \forall k = 1, \dots, N = 5000$$

- Qual a ordem da matriz $\mathbf{W}$?



Conjunto de dados.

- Note que o conjunto de dados tem $N = 5000$ vetores $\mathbf{x}_i \in \mathbb{R}^{1 \times 2}$ e 5000 vetores $\mathbf{y}_i \in \mathbb{R}^{1 \times 5}, i = 1, \dots, 5000$.
- O índice i denota a i -ésima amostra presente no conjunto de dados.
- É de interesse determinar uma matriz $\mathbf{W}$ que para um determinado dado vetor de entrada (amostra) $\mathbf{x}_i$ forneça uma predição do vetor-código associado ao gesto correspondente:

$$\mathbf{y}_i = \mathbf{x}_i \mathbf{W}, \quad \forall k = 1, \dots, N = 5000$$

- Qual a ordem da matriz $\mathbf{W}$? **Exatamente!!!**



Conjunto de dados.

- Note que o conjunto de dados tem $N = 5000$ vetores $\mathbf{x}_i \in \mathbb{R}^{1 \times 2}$ e 5000 vetores $\mathbf{y}_i \in \mathbb{R}^{1 \times 5}, i = 1, \dots, 5000$.
- O índice i denota a i -ésima amostra presente no conjunto de dados.
- É de interesse determinar uma matriz $\mathbf{W}$ que para um determinado dado vetor de entrada (amostra) $\mathbf{x}_i$ forneça uma predição do vetor-código associado ao gesto correspondente:

$$\mathbf{y}_i = \mathbf{x}_i \mathbf{W}, \quad \forall k = 1, \dots, N = 5000$$

- Qual a ordem da matriz $\mathbf{W}$? **Exatamente!!!** Sua ordem é 2×5 .
- Esta matriz representa a versão matemática que rotula gestos faciais.
- Qual a problemática desse modelo em específico?



Conjunto de dados.

- Note que o conjunto de dados tem $N = 5000$ vetores $\mathbf{x}_i \in \mathbb{R}^{1 \times 2}$ e 5000 vetores $\mathbf{y}_i \in \mathbb{R}^{1 \times 5}, i = 1, \dots, 5000$.
- O índice i denota a i -ésima amostra presente no conjunto de dados.
- É de interesse determinar uma matriz $\mathbf{W}$ que para um determinado dado vetor de entrada (amostra) $\mathbf{x}_i$ forneça uma predição do vetor-código associado ao gesto correspondente:

$$\mathbf{y}_i = \mathbf{x}_i \mathbf{W}, \quad \forall k = 1, \dots, N = 5000$$

- Qual a ordem da matriz $\mathbf{W}$? **Exatamente!!!** Sua ordem é 2×5 .
- Esta matriz representa a versão matemática que rotula gestos faciais.
- Qual a problemática desse modelo em específico? Exatamente também, o hiperplano que tentará dividir as classes está limitado à origem.



Conjunto de dados.

- Desta maneira, inicialmente deve-se para cada amostra considerar a existência de w_0 , ou seja, fazer com que $x_0 = 1$.
- Logo, $\mathbf{x}_i \in \mathbb{R}^{1 \times (p+1)}$, $i = 1, \dots, N$ e $p =$



Conjunto de dados.

- Desta maneira, inicialmente deve-se para cada amostra considerar a existência de w_0 , ou seja, fazer com que $x_0 = 1$.
- Logo, $\mathbf{x}_i \in \mathbb{R}^{1 \times (p+1)}$, $i = 1, \dots, N$ e $p = 2$
- Pode-se organizar todas as observações e seus rótulos nas linhas das matrizes $\mathbf{X}$ e $\mathbf{Y}$

$$\mathbf{X} = \begin{bmatrix} \mathbf{x}_1 \\ \mathbf{x}_2 \\ \vdots \\ \mathbf{x}_{5000} \end{bmatrix} \quad \text{e} \quad \mathbf{Y} = \begin{bmatrix} \mathbf{y}_1 \\ \mathbf{y}_2 \\ \vdots \\ \mathbf{y}_{5000} \end{bmatrix}$$

- Portanto, quais são as ordens de $\mathbf{X}$ e $\mathbf{Y}$?



Conjunto de dados.

- Desta maneira, inicialmente deve-se para cada amostra considerar a existência de w_0 , ou seja, fazer com que $x_0 = 1$.
- Logo, $\mathbf{x}_i \in \mathbb{R}^{1 \times (p+1)}$, $i = 1, \dots, N$ e $p = 2$
- Pode-se organizar todas as observações e seus rótulos nas linhas das matrizes $\mathbf{X}$ e $\mathbf{Y}$

$$\mathbf{X} = \begin{bmatrix} \mathbf{x}_1 \\ \mathbf{x}_2 \\ \vdots \\ \mathbf{x}_{5000} \end{bmatrix} \quad \text{e} \quad \mathbf{Y} = \begin{bmatrix} \mathbf{y}_1 \\ \mathbf{y}_2 \\ \vdots \\ \mathbf{y}_{5000} \end{bmatrix}$$

- Portanto, quais são as ordens de $\mathbf{X}$ e $\mathbf{Y}$?
- $\mathbf{X} \in \mathbb{R}^{5000 \times 3}$ e $\mathbf{Y} \in \mathbb{R}^{5000 \times 5}$.



Conjunto de dados.

- A versão matricial da transformação $\mathbf{y}_k = \mathbf{x}_k \mathbf{W}$ é dada por:

$$\mathbf{Y}_{[5000 \times 5]} = \mathbf{X}_{[5000 \times 3]} \mathbf{W}_{[3 \times 5]}$$



Conjunto de dados.

- A versão matricial da transformação $\mathbf{y}_k = \mathbf{x}_k \mathbf{W}$ é dada por:

$$\mathbf{Y}_{[5000 \times 5]} = \mathbf{X}_{[5000 \times 3]} \mathbf{W}_{[3 \times 5]}$$

- Note que as matrizes $\mathbf{X}$ e $\mathbf{Y}$ são montadas a partir do conhecimento dos dados, e a matriz $\mathbf{W}$ é



Conjunto de dados.

- A versão matricial da transformação $\mathbf{y}_k = \mathbf{x}_k \mathbf{W}$ é dada por:

$$\mathbf{Y}_{[5000 \times 5]} = \mathbf{X}_{[5000 \times 3]} \mathbf{W}_{[3 \times 5]}$$

- Note que as matrizes $\mathbf{X}$ e $\mathbf{Y}$ são montadas a partir do conhecimento dos dados, e a matriz $\mathbf{W}$ é **DESCONHECIDA**.
- Perguntas: A matriz $\mathbf{X}$ é quadrada?



Conjunto de dados.

- A versão matricial da transformação $\mathbf{y}_k = \mathbf{x}_k \mathbf{W}$ é dada por:

$$\mathbf{Y}_{[5000 \times 5]} = \mathbf{X}_{[5000 \times 3]} \mathbf{W}_{[3 \times 5]}$$

- Note que as matrizes $\mathbf{X}$ e $\mathbf{Y}$ são montadas a partir do conhecimento dos dados, e a matriz $\mathbf{W}$ é **DESCONHECIDA**.
- Perguntas: A matriz $\mathbf{X}$ é quadrada? Pode-se obter sua inversa de modo a isolar a matriz $\mathbf{W}$?



Conjunto de dados.

- A versão matricial da transformação $\mathbf{y}_k = \mathbf{x}_k \mathbf{W}$ é dada por:

$$\mathbf{Y}_{[5000 \times 5]} = \mathbf{X}_{[5000 \times 3]} \mathbf{W}_{[3 \times 5]}$$

- Note que as matrizes $\mathbf{X}$ e $\mathbf{Y}$ são montadas a partir do conhecimento dos dados, e a matriz $\mathbf{W}$ é **DESCONHECIDA**.
- Perguntas: A matriz $\mathbf{X}$ é quadrada? Pode-se obter sua inversa de modo a isolar a matriz $\mathbf{W}$?
- E se $\mathbf{X}$ fosse uma matriz quadrada?



Conjunto de dados.

- A versão matricial da transformação $\mathbf{y}_k = \mathbf{x}_k \mathbf{W}$ é dada por:

$$\mathbf{Y}_{[5000 \times 5]} = \mathbf{X}_{[5000 \times 3]} \mathbf{W}_{[3 \times 5]}$$

- Note que as matrizes $\mathbf{X}$ e $\mathbf{Y}$ são montadas a partir do conhecimento dos dados, e a matriz $\mathbf{W}$ é **DESCONHECIDA**.
- Perguntas: A matriz $\mathbf{X}$ é quadrada? Pode-se obter sua inversa de modo a isolar a matriz $\mathbf{W}$?
- E se $\mathbf{X}$ fosse uma matriz quadrada? Para isolar a matriz $\mathbf{W}$, pode-se usar o artifício que se segue.

$$\mathbf{X}^T \mathbf{Y} = \mathbf{X}^T \mathbf{X} \mathbf{W}$$



Conjunto de dados.

- A versão matricial da transformação $\mathbf{y}_k = \mathbf{x}_k \mathbf{W}$ é dada por:

$$\mathbf{Y}_{[5000 \times 5]} = \mathbf{X}_{[5000 \times 3]} \mathbf{W}_{[3 \times 5]}$$

- Note que as matrizes $\mathbf{X}$ e $\mathbf{Y}$ são montadas a partir do conhecimento dos dados, e a matriz $\mathbf{W}$ é **DESCONHECIDA**.
- Perguntas: A matriz $\mathbf{X}$ é quadrada? Pode-se obter sua inversa de modo a isolar a matriz $\mathbf{W}$?
- E se $\mathbf{X}$ fosse uma matriz quadrada? Para isolar a matriz $\mathbf{W}$, pode-se usar o artifício que se segue.

$$\mathbf{X}^T \mathbf{Y} = \mathbf{X}^T \mathbf{X} \mathbf{W}$$

$$\mathbf{X}_{[3 \times 5000]}^T \mathbf{Y}_{[5000 \times 5]} = \mathbf{X}_{[3 \times 5000]}^T \mathbf{X}_{[5000 \times 3]} \mathbf{W}_{[3 \times 5]}$$



Conjunto de dados.

- O que acontece quando se computa $\mathbf{X}^T \mathbf{X}$??



Conjunto de dados.

- O que acontece quando se computa $\mathbf{X}^T \mathbf{X}$??
- Como se trata de uma matriz quadrada, pode-se computar a sua inversa.
- Portanto, ao multiplicar ambos os lados da equação pela inversa de $\mathbf{X}^T \mathbf{X}$, tem-se:

$$(\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{Y} = (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{X} \mathbf{W}$$



Conjunto de dados.

- O que acontece quando se computa $\mathbf{X}^T \mathbf{X}$??
- Como se trata de uma matriz quadrada, pode-se computar a sua inversa.
- Portanto, ao multiplicar ambos os lados da equação pela inversa de $\mathbf{X}^T \mathbf{X}$, tem-se:

$$(\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{Y} = (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{X} \mathbf{W}$$

$$\mathbf{W} = (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{Y}$$

- Como seria uma formalização para um problema genérico? Com N amostras, p preditores e C classes.



Abrindo um parêntesis com notificação importante.

- Vejam, é importante aqui destacar um detalhe já discutido em sala de aula.
- A depender da construção do conjunto de dados, as ordens das matrizes ou vetores, poderiam estar transpostas.
- Exemplo: imagine que os dados disponíveis sejam: $\mathbf{X} \in \mathbb{R}^{p \times N}$, $\mathbf{Y} \in \mathbb{R}^{C \times N}$. O que fazer nesse caso?



Abrindo um parêntesis com notificação importante.

- Vejam, é importante aqui destacar um detalhe já discutido em sala de aula.
- A depender da construção do conjunto de dados, as ordens das matrizes ou vetores, poderiam estar transpostas.
- Exemplo: imagine que os dados disponíveis sejam: $\mathbf{X} \in \mathbb{R}^{p \times N}$, $\mathbf{Y} \in \mathbb{R}^{C \times N}$. O que fazer nesse caso?
- Bom, a princípio pode-se pensar em transpor as matrizes de modo a manter a estrutura exibida nos slides anteriores.
- Contudo, pela álgebra linear, pode-se estimar os coeficientes de $\mathbf{W}$ pelo mesmo princípio:

$$\mathbf{Y} = \mathbf{W}\mathbf{X}$$

- Logo, pode-se tentar isolar $\mathbf{W}$ na tentativa de criar uma matriz quadrada com inversa.



Abrindo um parêntesis com notificação importante.

- Logo, pode-se tentar isolar $\mathbf{W}$ na tentativa de criar uma matriz quadrada $\mathbf{X}\mathbf{X}^T$ com inversa. Então, faz-se

$$\mathbf{Y} = \mathbf{W}\mathbf{X}$$



Abrindo um parêntesis com notificação importante.

- Logo, pode-se tentar isolar W na tentativa de criar uma matriz quadrada XX^T com inversa. Então, faz-se

$$Y = WX$$

$$YX^T = WXX^T$$

$$YX^T(XX^T)^{-1} = WXX^T(XX^T)^{-1}$$

$$W = YX^T(XX^T)^{-1}$$

- Qual diferença deste W para o estimado nos slides anteriores? As informações dos coeficientes estarão compostas em ambos vetores (ou matrizes)?



...Continuando...Regularização por Tikhonov.

- Qual(is) problemática(s) que está(ão) relacionada(s) a matriz $\mathbf{X}^T \mathbf{X}$ (para o caso $\mathbf{X} \in \mathbb{R}^{N \times (p+1)}$)



...Continuando...Regularização por Tikhonov.

- Qual(is) problemática(s) que está(ão) relacionada(s) a matriz $\mathbf{X}^T\mathbf{X}$ (para o caso $\mathbf{X} \in \mathbb{R}^{N \times (p+1)}$)
- Para evitar o mau-condicionamento, costuma-se fazer o uso da regularização por Tikhonov.
- Nesta, a matriz $\mathbf{W}$ passa a ser estimada por meio da seguinte expressão:

$$\mathbf{W} = (\mathbf{X}^T\mathbf{X} + \lambda\mathbf{I})^{-1}\mathbf{X}^T\mathbf{Y}$$

- Em que $0 < \lambda \leq \infty$ é chamada de constante de regularização e $\mathbf{I} \in \mathbb{R}^{p+1 \times p+1}$
- Perceba que λ é um **hiperparâmetro**.
- Um hiperparâmetro é uma definição realizada pelo projetista para que os parâmetros da função discriminante propriamente dita possam ser estimados.
- Qual problemática ao se ter hiperparâmetros?



Predição a partir do modelo gerado.

- De posse da matriz $\mathbf{W}$, podemos utilizá-la como componente de software de tomada de decisão para classificar as expressões faciais.
- Matematicamente, isto pode ser realizado por meio da seguinte equação:

$$\mathbf{y} = \mathbf{x}\mathbf{W}$$

- Cada uma das saídas individuais poderiam ainda ser escritas como:

$$y_i = \mathbf{x}\mathbf{w}_i$$

- Essa expressão chama-se função discriminante linear da i -ésima classe.



Predição a partir do modelo gerado.

- Desta maneira, imagine que um sinal seja adquirido referente aos dois sensores.

$$\mathbf{x}_{novo} = [1 \quad sens1 \quad sens2]$$

- Ao multiplicarmos estes pela matriz $\mathbf{W}$, obtemos o vetor de saídas $\mathbf{y}_{novo} = \mathbf{x}_{novo} \mathbf{W}$.

$$[\hat{y}_1 \quad \hat{y}_2 \quad \hat{y}_3 \quad \hat{y}_4 \quad \hat{y}_5]$$

- Por tratar de um produto interno, utiliza-se como regra de decisão a seguinte expressão:

$$j^* = \text{índice da classe de } \mathbf{x}_{novo} = \arg \max \{\hat{y}_j\} \forall j$$

- A função *max* retorna o maior valor entre todas as saídas $\hat{y}_j$, e a função *arg* retorna seu índice.



O que fazer?

- O que fazer, quando há a posse dos dados?
- Destaca-se que o conjunto de dados é disposto da seguinte maneira:
 - 1 Será disponibilizado inicialmente, os dados referentes a duas classes.
 - 2 Para cada gesto, tem-se 1000 amostras do sensor 1 e 1000 do sensor 2.
 - 3 Portanto, inicialmente é necessário organizar os dados da seguinte maneira $\mathbf{X} \in \mathbb{B}^{N \times P}$ e $\mathbf{Y} \in \mathbb{B}^{N \times C}$.
- As amostras então, devem ser embaralhadas.
- Em sequência, deve-se dividir as amostras N do conjunto de dados em treino/teste (comumente nas proporções 80/20 ou 70/30 ou 90/10) .
- Pode-se calcular a Taxa de acerto do classificador usando o seguinte cálculo:

$$TxA = \frac{\text{Qtd de predições corretas}}{\text{Total de amostras de teste}}$$

- Quão confiável é essa taxa de acerto? Como melhorá-la?




O que fazer?

Considerando:

$$\mathbf{x} \in \mathbb{R}^{1 \times (p+1)} \quad \mathbf{y} \in \mathbb{R}^{1 \times c} \quad N = 10$$

$\mathbf{x}_1 | \mathbf{y}_1$
 $\mathbf{x}_2 | \mathbf{y}_2$
 $\mathbf{x}_3 | \mathbf{y}_3$
 $\mathbf{x}_4 | \mathbf{y}_4$
 $\mathbf{x}_5 | \mathbf{y}_5$
 $\mathbf{x}_6 | \mathbf{y}_6$
 $\mathbf{x}_7 | \mathbf{y}_7$
 $\mathbf{x}_8 | \mathbf{y}_8$
 $\mathbf{x}_9 | \mathbf{y}_9$
 $\mathbf{x}_{10} | \mathbf{y}_{10}$

Embaralha



$\mathbf{x}_4 | \mathbf{y}_4$
 $\mathbf{x}_7 | \mathbf{y}_7$
 $\mathbf{x}_2 | \mathbf{y}_2$
 $\mathbf{x}_6 | \mathbf{y}_6$
 $\mathbf{x}_5 | \mathbf{y}_5$
 $\mathbf{x}_3 | \mathbf{y}_3$
 $\mathbf{x}_9 | \mathbf{y}_9$
 $\mathbf{x}_1 | \mathbf{y}_1$
 $\mathbf{x}_{10} | \mathbf{y}_{10}$
 $\mathbf{x}_8 | \mathbf{y}_8$

80/20



Treino

$\mathbf{x}_4 | \mathbf{y}_4$
 $\mathbf{x}_7 | \mathbf{y}_7$
 $\mathbf{x}_2 | \mathbf{y}_2$
 $\mathbf{x}_6 | \mathbf{y}_6$
 $\mathbf{x}_5 | \mathbf{y}_5$
 $\mathbf{x}_3 | \mathbf{y}_3$
 $\mathbf{x}_9 | \mathbf{y}_9$
 $\mathbf{x}_1 | \mathbf{y}_1$

Teste

$\mathbf{x}_{10} | \mathbf{y}_{10}$
 $\mathbf{x}_8 | \mathbf{y}_8$

Estimação do modelo

$$\hat{\mathbf{W}} = (\mathbf{X}_{treino}^T \mathbf{X}_{treino})^{-1} \mathbf{X}_{treino}^T \mathbf{Y}$$

Predição

$$\mathbf{y}_{predito} = \mathbf{X}_{teste} \hat{\mathbf{W}}$$



Dilema viés-variância.

- Já foi discutido que uma das maneiras de avaliar o desempenho de modelos de regressão, através da minimização da medida de desvios quadráticos, dada pela equação:



Dilema viés-variância.

- Já foi discutido que uma das maneiras de avaliar o desempenho de modelos de regressão, através da minimização da medida de desvios quadráticos, dada pela equação:


$$MSE = \frac{1}{N} \sum_{i=1}^N (y_i - \hat{f}(x_i))^2$$

- Nesta, $\hat{f}$ representa o modelo estimado, e x_i é a i -ésima amostra.
- Neste caso, MSE pode ser calculado tanto na etapa de treinamento quando na etapa de teste.
- Essa abordagem abre discussões importantes sobre a estimação de modelos em geral.
- No caso da estimação do MMQO, uma minimização de MSE de treino é interessante? E para métodos não-lineares como essa análise é realizada?



Dilema viés-variância.


- O que dizer sobre a imagem?





Dilema viés-variância.


- O que dizer sobre a imagem?





Dilema viés-variância.


- O que dizer sobre a imagem?





Dilema viés-variância.


- O que dizer sobre a imagem?





Dilema viés-variância.


- O que dizer sobre a imagem?





Dilema viés-variância.


- O que dizer sobre a imagem?






Dilema viés-variância.

- O que dizer sobre a imagem?






Dilema viés-variância.



- Essa característica de declínio monotônico no MSE de treino e forma de U no MSE do teste, é presente em diversos métodos estatísticos, independente dos dados.
- A medida que a flexibilidade do modelo é aumentada, MSE de treinamento diminui, contudo, MSE do teste pode não desempenhar da mesma maneira.
- Quando um modelo proporciona um baixo MSE de treino e um alto MSE de teste, é dito que o modelo **sobreajusta** os dados (*overfitting*).
- Deve-se levar em consideração que ocorrendo ou não um *overfitting*, é esperado que o MSE de treinamento seja inferior ao MSE de teste.
- Alguém arrisca dizer o motivo?




Dilema viés-variância.



- Essa característica de declínio monotônico no MSE de treino e forma de U no MSE do teste, é presente em diversos métodos estatísticos, independente dos dados.
- A medida que a flexibilidade do modelo é aumentada, MSE de treinamento diminui, contudo, MSE do teste pode não desempenhar da mesma maneira.
- Quando um modelo proporciona um baixo MSE de treino e um alto MSE de teste, é dito que o modelo **sobreajusta** os dados (*overfitting*).
- Deve-se levar em consideração que ocorrendo ou não um *overfitting*, é esperado que o MSE de treinamento seja inferior ao MSE de teste.
- Alguém arrisca dizer o motivo? Exatamente!



Dilema viés-variância.



- Essa característica de declínio monotônico no MSE de treino e forma de U no MSE do teste, é presente em diversos métodos estatísticos, independente dos dados.
- A medida que a flexibilidade do modelo é aumentada, MSE de treinamento diminui, contudo, MSE do teste pode não desempenhar da mesma maneira.
- Quando um modelo proporciona um baixo MSE de treino e um alto MSE de teste, é dito que o modelo **sobreajusta** os dados (*overfitting*).
- Deve-se levar em consideração que ocorrendo ou não um *overfitting*, é esperado que o MSE de treinamento seja inferior ao MSE de teste.
- Alguém arrisca dizer o motivo? Exatamente! A maioria dos modelos busca a estimação de seus parâmetros através da minimização do MSE de treinamento.



Dilema viés-variância.

- A forma em U exibida anteriormente, é resultado de duas propriedades importantes em modelos de machine learning.
- Para minimizar o MSE de teste, é necessário encontrar um modelo que simultaneamente possua uma baixa variância e um baixo viés (*bias*).
- Nesse contexto, a **variância** do modelo é a capacidade que ele tem de modificar sua estimação quando utiliza-se diferentes conjuntos de dados. Pelas discussões realizadas, é interessante que essa estimativa não cause uma diferença tão grande entre conjuntos de treinamento.
- Nesse contexto, *bias* trata-se da incapacidade do modelo de capturar as verdadeiras relações entre entrada e saída.
- Como exemplo, pode-se dizer que uma regressão linear, possui uma alta quantidade relativa de viés.
- Uma aproximação polinomial de alta ordem, consegue ser muito flexível e assim, possui baixo viés.