

Modelos de Regressão e Classificação Linear por Mínimos Quadrados: Aplicação ao PIB da China e Sinais de EMG Facial

Rafael Cacau Igor Praciano
Centro de Ciências Tecnológicas (CCT)
Universidade de Fortaleza (UNIFOR)

Inteligência Artificial Computacional — Prof. Msc. Paulo Cirillo Souza Barbosa
Fortaleza, Ceará, Brasil

Resumo—Neste trabalho foram estudados modelos baseados no método dos Mínimos Quadrados Ordinários (MQO), implementados utilizando operações matriciais em NumPy. Foram analisados dois problemas: a regressão do PIB da China e a classificação de sinais de eletromiografia (EMG) facial. Na regressão, foram comparados o modelo linear, o modelo com regularização de Tikhonov e o modelo polinomial com diferentes ordens. Na classificação, foi utilizada uma abordagem One-vs-All para separar cinco expressões faciais a partir de dois sinais de EMG. Os modelos foram avaliados por meio de 500 divisões aleatórias dos dados, usando 80% das amostras para treinamento e 20% para teste. Nos experimentos realizados, o modelo polinomial apresentou os melhores resultados, com $R^2 = 0,9949$ para a regressão com $q = 9$ e acurácia média de 99,28% para a classificação com $q = 4$.

Index Terms—Mínimos Quadrados, Regressão Linear, Regularização de Tikhonov, Eletromiografia, Classificação Multiclasse.

I. INTRODUÇÃO

Neste trabalho são estudados modelos de aprendizagem supervisionada aplicados a dois problemas diferentes. O primeiro é um problema de regressão, no qual o objetivo é estimar um valor contínuo. O segundo é um problema de classificação, no qual cada amostra deve ser associada a uma das classes disponíveis.

O método dos Mínimos Quadrados Ordinários (MQO) é utilizado como base para os modelos estudados. Ele permite encontrar os coeficientes que minimizam o erro quadrático entre os valores reais e os valores estimados. Apesar de o modelo linear ser simples, ele pode apresentar dificuldades quando os dados possuem uma relação que não pode ser bem representada por uma reta.

Uma alternativa utilizada neste trabalho foi a expansão polinomial. Nesse caso, novas entradas são criadas a partir de potências das variáveis originais, permitindo que o modelo represente relações curvas. Também foi analisada a regularização de Tikhonov, com o objetivo de observar seu efeito sobre os coeficientes encontrados pelo MQO.

Os dois problemas utilizados nos experimentos foram:

- 1) **Regressão do PIB da China:** estimar o PIB em dólares a partir do ano da medição, utilizando o arquivo `china_gdp.csv`.

- 2) **Classificação de sinais de EMG:** identificar cinco expressões faciais a partir de dois sensores de eletromiografia, utilizando os arquivos `EMGDataset.csv` e `EMG1.csv`.

Os modelos foram implementados sem o uso de bibliotecas que já fornecem algoritmos de aprendizagem prontos, como o scikit-learn.

II. METODOLOGIA

A. Dados utilizados e normalização

Para a regressão do PIB da China, foram utilizadas $N = 55$ amostras, correspondentes aos anos de 1960 a 2014, com uma variável de entrada:

$$X \in \mathbb{R}^{55 \times 1}, \quad y \in \mathbb{R}^{55 \times 1}. \quad (1)$$

Para a classificação dos sinais de EMG, foram utilizadas $N = 50.000$ amostras, com dois sensores faciais e cinco classes. Os sensores utilizados foram o Corrugador do Supercílio e o Zigomático Maior. As classes são: 1–Neutro, 2–Sorriso, 3–Sobrancelhas levantadas, 4–Surpreso e 5–Rabugento.

A matriz de saída possui uma coluna para cada classe:

$$X \in \mathbb{R}^{50000 \times 2}, \quad Y \in \mathbb{R}^{50000 \times 5}. \quad (2)$$

Antes do treinamento, os dados foram padronizados utilizando o Z-score. Para cada variável, foi utilizada a média e o desvio padrão calculados no conjunto de treinamento:

$$z = \frac{x - \mu_{\text{treino}}}{\sigma_{\text{treino}}}. \quad (3)$$

A mesma média e o mesmo desvio padrão obtidos no treinamento foram utilizados para transformar os dados de teste. Dessa forma, as informações do conjunto de teste não são utilizadas durante o treinamento.

B. Modelos

1) *Modelo polinomial*: Para representar relações não lineares, a entrada foi expandida com potências até a ordem q . Foi incluído também o termo constante para representar o intercepto:

$$X_q = [1, X, X^2, \dots, X^q]. \quad (4)$$

Quando $q = 1$, o modelo corresponde ao caso linear com intercepto.

A notação X_q é utilizada aqui para representar a matriz de entrada depois da expansão polinomial. Assim, as equações seguintes utilizam a mesma matriz, sem a necessidade de introduzir uma segunda notação para a matriz de características.

2) *MQO tradicional*: Os coeficientes do modelo são obtidos minimizando a soma dos erros quadráticos. A solução utilizada foi:

$$\beta = (X_q^T X_q)^{-1} X_q^T Y. \quad (5)$$

Na implementação, também pode ser utilizada a pseudoinversa de Moore-Penrose para obter uma solução mais estável quando a matriz não possui inversa direta:

$$\beta = X_q^\dagger Y. \quad (6)$$

3) *MQO com regularização de Tikhonov*: No modelo regularizado, é adicionada uma parcela à matriz usada no cálculo dos coeficientes:

$$\beta = (X_q^T X_q + \lambda I)^{-1} X_q^T Y, \quad (7)$$

onde λ representa o parâmetro de regularização e I é a matriz identidade.

Foram testados os valores:

$$\lambda \in \{0; 0,25; 0,5; 0,75; 1\}. \quad (8)$$

A ideia é verificar se a alteração dos coeficientes provocada pela regularização produz alguma melhora nos resultados.

4) *Classificação multiclasse*: Para a classificação, os rótulos foram representados utilizando +1 para a classe correspondente e -1 para as demais classes. Depois de calcular os coeficientes, a classe escolhida para uma nova amostra é aquela que apresenta o maior valor de saída:

$$\hat{c} = \arg \max_{j \in \{1, \dots, C\}} (X_q(x)^T \beta)_j. \quad (9)$$

C. Validação dos modelos

Para comparar os modelos, foram realizadas 500 divisões aleatórias dos dados. Em cada rodada, 80% das amostras foram utilizadas para treinamento e 20% para teste.

- $R = 500$ rodadas;
- 80% dos dados para treinamento;
- 20% dos dados para teste.

Na regressão foram calculados o Erro Quadrático Médio (MSE) e o coeficiente de determinação (R^2):

$$MSE = \frac{1}{N} \sum (y - \hat{y})^2 \quad (10)$$

e

$$R^2 = 1 - \frac{\sum (y - \hat{y})^2}{\sum (y - \bar{y})^2}. \quad (11)$$

Na classificação, foi utilizada a acurácia, calculada pela porcentagem de amostras classificadas corretamente.

III. RESULTADOS E DISCUSSÃO

A. Regressão do PIB da China

A primeira análise foi feita com os dados do PIB da China. A Fig. 1 apresenta os dados e os ajustes obtidos pelos modelos. É possível observar que o crescimento do PIB não segue uma tendência linear ao longo de todo o período. O crescimento se torna mais acentuado principalmente a partir da década de 1990.




Figura 1. Ajuste dos modelos lineares e polinomial sobre o PIB da China.

Foram testadas ordens polinomiais de $q = 1$ até $q = 10$. O valor médio de R^2 aumentou até a ordem $q = 9$, que apresentou $R^2 = 0,9965$. Para $q = 10$, houve aumento da variância sem uma melhora relevante no R^2 . Por esse motivo, foi escolhida a ordem $q = 9$.

A Tabela I apresenta os valores dos coeficientes encontrados para os modelos lineares. É possível observar uma redução gradual da norma dos coeficientes conforme o valor de λ aumenta.

Tabela I
ESTIMATIVAS DE β E NORMA PARA OS MODELOS LINEARES

Modelo	λ	β_0	β_1	$\ \beta\ $
MQO Tradicional	0,00	$1,437 \times 10^{12}$	$1,793 \times 10^{12}$	$2,298 \times 10^{12}$
MQO Reg. (0,25)	0,25	$1,431 \times 10^{12}$	$1,785 \times 10^{12}$	$2,288 \times 10^{12}$
MQO Reg. (0,50)	0,50	$1,424 \times 10^{12}$	$1,777 \times 10^{12}$	$2,277 \times 10^{12}$
MQO Reg. (0,75)	0,75	$1,418 \times 10^{12}$	$1,769 \times 10^{12}$	$2,267 \times 10^{12}$
MQO Reg. (1,00)	1,00	$1,411 \times 10^{12}$	$1,761 \times 10^{12}$	$2,257 \times 10^{12}$

A Tabela II reúne os resultados obtidos nas 500 rodadas de validação.

Os modelos lineares apresentaram R^2 médio negativo. Isso mostra que, para as divisões de teste utilizadas, uma reta

Tabela II
DESEMPENHO DOS MODELOS DE REGRESSÃO ($R = 500$ RODADAS)

Modelo	MSE Médio	R^2 Médio	Desvio R^2	Melhor R^2
Polinomial ($q = 9$)	$1,45 \times 10^{22}$	0,9949	0,0145	0,9999
MQO tradicional	$3,38 \times 10^{24}$	-1,3214	9,5537	0,7586
MQO reg. ($\lambda = 0,25$)	$3,38 \times 10^{24}$	-1,2942	9,4380	0,7570
MQO reg. ($\lambda = 0,50$)	$3,37 \times 10^{24}$	-1,2676	9,3244	0,7555
MQO reg. ($\lambda = 0,75$)	$3,37 \times 10^{24}$	-1,2415	9,2128	0,7539
MQO reg. ($\lambda = 1,00$)	$3,37 \times 10^{24}$	-1,2160	9,1031	0,7522

não conseguiu acompanhar bem o crescimento do PIB. A regularização apresentou uma pequena melhora no valor médio de R^2 , mas não muda o fato de que o modelo continua sendo linear.

O modelo polinomial de ordem $q = 9$ apresentou um resultado bem diferente, com R^2 médio de 0,9949. Nesse caso, a expansão das entradas permitiu representar melhor a curva observada nos dados.

B. Classificação de sinais de EMG facial

Na segunda parte do trabalho foram utilizados sinais de EMG obtidos com sensores Myoware e um microcontrolador ESP32. Os sinais foram coletados a uma taxa de 1 kHz, com resolução de 12 bits, variando de 0 a 4095. Foram utilizados dois músculos faciais: Corrugador do Supercílio e Zigomático Maior.

As cinco classes consideradas foram Neutro, Sorriso, Sobrancelhas Levantadas, Surpreso e Rabugento.

A Fig. 2 apresenta a distribuição das amostras. Pode-se observar que as classes não são separadas apenas por retas, existindo regiões de sobreposição entre elas.




Figura 2. Dispersão dos sinais de EMG dos sensores faciais para as 5 classes.

Para o modelo polinomial, foram testadas ordens de $q = 1$ até $q = 6$. As acurácias obtidas foram, respectivamente, 72,53%, 94,49%, 97,64%, 99,24%, 99,26% e 99,30%.

A ordem $q = 4$ foi escolhida considerando o resultado de acurácia e o tempo de treinamento. Apesar de as ordens seguintes apresentarem valores próximos ou ligeiramente

superiores, o modelo de ordem 4 já apresentou mais de 99,2% de acerto com tempo de cálculo inferior a 0,05 segundos.

A Fig. 3 mostra as regiões de decisão dos modelos. No modelo linear, as fronteiras são retas e possuem maior dificuldade para separar algumas das classes. Com a expansão polinomial, as fronteiras podem assumir formatos curvos e acompanhar melhor a distribuição das amostras.




Figura 3. Regiões e fronteiras de decisão dos modelos de classificação.

A Tabela III apresenta os resultados das 500 rodadas de validação. A distribuição das acurácias pode ser observada na Fig. 4.

Tabela III
DESEMPENHO DOS CLASSIFICADORES ($R = 500$ RODADAS)

Modelo	Acurácia Média	Desvio-Padrão	Maior	Menor
MQO tradicional	72,3888%	0,6430%	74,18%	70,13%
MQO regularizado ($\lambda = 0,25$)	72,3890%	0,6428%	74,18%	70,13%
MQO Polinomial ($q = 4$)	99,2799%	0,0829%	99,48%	99,06%




Figura 4. Distribuição da acurácia nas 500 rodadas de validação.

O classificador polinomial apresentou acurácia média de 99,28%, com desvio padrão de 0,08%. Em todas as rodadas, a acurácia ficou acima de 99%.

Para o modelo linear, a regularização com $\lambda = 0,25$ praticamente não alterou a acurácia. Isso indica que, neste conjunto de dados, a principal diferença entre os modelos está na capacidade de representar fronteiras de decisão curvas.

IV. CONCLUSÕES

Os experimentos realizados permitiram comparar o comportamento do MQO tradicional, da regularização de Tikhonov e da expansão polinomial em dois problemas diferentes.

Na regressão do PIB da China, os modelos lineares apresentaram resultados inferiores aos do modelo polinomial. O melhor resultado foi obtido com a ordem $q = 9$, que apresentou R^2 médio de 0,9949. Isso mostra que, para os dados utilizados, a relação entre o ano e o PIB foi melhor representada utilizando os termos polinomiais.

Na classificação dos sinais de EMG, também houve uma diferença significativa entre o modelo linear e o modelo polinomial. A acurácia média passou de aproximadamente 72,39% no modelo linear para 99,28% no modelo polinomial de ordem $q = 4$.

A regularização de Tikhonov reduziu a norma dos coeficientes dos modelos de regressão, mas teve pouca influência no desempenho final dos modelos analisados. Já a expansão polinomial apresentou uma mudança maior nos resultados, principalmente porque permitiu representar relações não lineares presentes nos dados.

Por fim, os testes com diferentes ordens polinomiais ajudaram a escolher valores que apresentaram bons resultados sem utilizar uma ordem maior do que a necessária nos experimentos realizados. Para a regressão foi escolhida a ordem $q = 9$ e, para a classificação, a ordem $q = 4$.